Úvod, instalace R a Rstudia, základní datové typy a struktury operace, čísla, vektory a práce s nimi

17VSADR – Skriptování a analýza dat v jazyce R

Lubomír Štěpánek^{1, 2}



 Oddělení biomedicínské statistiky Ústav biofyziky a informatiky
 lékařská fakulta
 Univerzita Karlova v Praze



²Katedra biomedicínské informatiky Fakulta biomedicínského inženýrství České vysoké učení technické v Praze

(2018) Lubomír Štěpánek, CC BY-NC-ND 3.0 (CZ)



Dílo lze dále svobodně šířit, ovšem s uvedením původního autora a s uvedením původní licence. Dílo není možné šířit komerčně ani s ním jakkoliv jinak nakládat pro účely komerčního zisku. Dílo nesmí být jakkoliv upravováno. Autor neručí za správnost informací uvedených kdekoliv v předložené práci, přesto vynaložil nezanedbatelné úsilí, aby byla uvedená fakta správná a aktuální, a práci sepsal podle svého nejlepšího vědomí a svých "nejlepších" znalostí problematiky.

Obsah

- Organizace
- Úvod
- Začínáme
- Datové typy, jejich vlastnosti
- Datové struktury
- Wektory a operace s nimi

1. října 2018

Organizace předmětu

- volitelný předmět (2 kreditové body)
- zakončen zápočtem
- rozsah 0 + 2 (vyučovacích hodin týdně)
- neoficiální účast na bázi dobrovolnosti vítána

1. října 2018

Zápočet

- zápočet bude udělen za
 - alespoň rozumnou účast na cvičeních
 - odevzdání alespoň rozumného množství domácích úkolů

1. října 2018

Online supplementum

fakultní stránka předmětu ▶ FBMI

https://predmety.fbmi.cvut.cz/cs/17VSADR

githubí stránka předmětu ▶ GitHub

https://github.com/LStepanek/17VSADR Skriptovani a analyza dat v jazyce R

6/61

Literatura

- Karel Zvára. Základy statistiky v prostředí R. Praha, Česká republika: Karolinum, 2013. ISBN: 978-80-246-2245-3.
- Hadley Wickham. Advanced R. Boca Raton, FL: CRC Press, 2015. ISBN: 978-1466586963.

Proč bych se právě já měl učit s R

- s vědou (nejen) v biomedicíně to myslím vážně
- chtěl bych se věnovat postgraduálnímu doktorskému studiu, kde jistojistě budu potřebovat statistiku
- jsem postgraduální student a jednou bych chtěl dokončit postgraduální doktorské studium, k čemuž tu zatracenou statistiku opravdu potřebuji
- jsem lékař a hledám konečně efektivní nástroj pro analýzy svých výzkumů
- komerční statistické programy pro mě nejsou dostupné, nebo nejsou dobře použitelné
- sbírám opakovaně data stejného charakteru a rád bych si jejich (před)zpracování automatizoval



Proč bych se právě já měl učit s R

- publikuji v odborných časopisech a rád bych do statě článku s Methodology and Statistical Analysis pravdivě psal, že "... all statistical analyses were performed using R language for statistical computing and graphics...", protože existují důkazy, že citování R či jiných volných statistických nástrojů mnohdy zvyšuje pravděpodobnost citování takového článku
- tuším, že věda 2.0 v biomedicíně se bude provozovat nejen formou experimentů na živém (in vivo) či v laboratořích (in vitro), ale budou ji tvořit ze značné části počítačové modely a simulace (in silico)
- uvědomuji si, že MS Excel v základním rozhraní neumí doteď vykreslit krabicový diagram



Proč bych se právě já měl učit s R

- zpracování dat v tabulkových procesorech a spoléhání se jen na ně je spjato s různými problémy, chybné výstupy z tabulkových procesorů dokonce vyvolaly některé vědecké skandály
- data již nějakou dobu (sám) analyzují a přemýšlím, který nástroj pro analýzu (s kvalitní dokumentací a živou podporou a komunitou) se začít učit

Co je R



- R je interpretovaný programovací jazyk
- kombinuje několik paradigmat
 - imperativní
 - funkcionální
 - objektové
- R je domain specific language je určen pro statistickou analýzu dat a jejich grafické zobrazení
- R je open-source, konkrétně free-as-in-beer a free-as-in-speech

Stručná historie R

- R vychází z jazyka a prostředí S, které vyvinuto v Bellových laboratořích v letech 1975-1976 (prof. Johne Chambers)
- přerod v R v roce 1992 na Acklandské univerzitě na Novém Zélandu (prof. Ross Ihaka a Robert Gentleman)
- R je tedy akcentem S
- v roce 1994 první verze prostředí R pro volné použití, poté postupně vzniká řada dalších verzí, v září 2017 poslední verze R 3.4.3 ("Short Summer")
- za otce moderního R považován Hadley Wickham (leader analyst v RStudiu, adj. prof. na Aucklandské univerzitě)

Stažení a instalace jádra R

na stránkách R-projectu

https://www.r-project.org/

postupně download R, vyberme českou doménu a stáhněme desktopově

poté instalujme dle instrukcí do předvolené složky

Stažení a instalace RStudia

- RStudio je jedním z grafických IDE (Integrated Development Environment) jazyka R
- na stránkách RStudia

https://www.rstudio.com/

postupně Products > RStudio > Desktop > Open Source Edition > Free > Download, stáhněme desktopově

poté instalujme dle instrukcí do předvolené složky

Další software

- může (a bude) se časem hodit i
 - obecný textový editor, např. Notepad++

https://notepad-plus-plus.org/

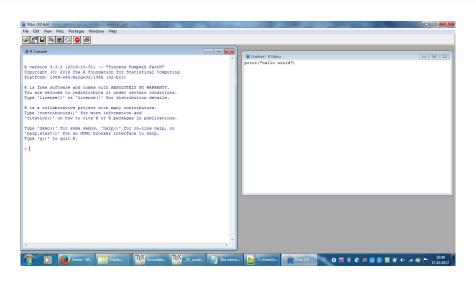
univerzální konvertor dokumentů Pandoc

https://pandoc.org/

typografický sázeč TFX

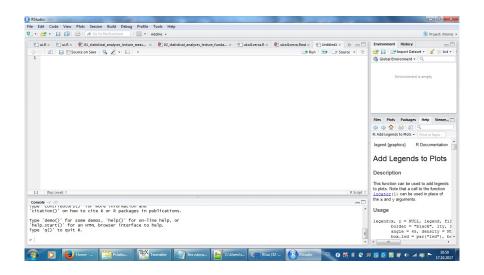
https://miktex.org/

První spuštění R jádra



16/61

První spuštění RStudia



Ahoj světe!

do skriptu či konzole napišme

```
print("hello world")
```

dostaneme

```
[1] "hello world"
```

Práce s nápovědou

 nápovědu pro funkci či objekt získáme pomocí příkazu help(), kde argumentem je název funkce či objektu

```
help(print)
```

nebo předsazením symbolu ? před název funkce či objektu

```
?print
```

 předsazením symbolů ?? před název funkce či objektu prohledáme veškeré dokumenty nápovědy

```
??print
```

vždy je zavolán HTML soubor s volnotextovou nápovědou

Přístup k práci v R

- interaktivní práce mezi skriptem a konzolí (shell programming)
- (dávkové) volání skriptů
 - (i) vytvoření funkčního skriptu s příponou .R
 - uložení skriptu do pracovní složky, kterou zjistíme pomocí příkazu getwd()
 - (iii) zavolání a exekuce skriptu v konzoli pomocí příkazu source(nazev_skriptu.R)

20/61

Intermezzo

uložme následující kód jako scitam_dve_cisla.R

```
print(a + b)
```

skript scitam_dve_cisla.R přesuňme do složky, kterou vrátí příkaz

```
getwd()
```

anebo vhodně nastavme pracovní složku pomocí příkazu

```
setwd(choose.dir())
```

do konzole nyní napišme

```
source("scitam_dve_cisla.R")
```

Instalace nadstavbových balíčků

nejlépe pomocí příkazu

```
install.packages (
    "nazev_balicku".
    dependencies = TRUE,
    repos = "http://cran.us.r-project.org"
```

- poslední argument repos není nutný, ale je šikovný, vybere doménu, z které balíček stáhnout, aniž by ji musel uživatel vybrat kliknutím v pop-up okně (vhodné pro úplnou automatizaci kódu)
- zkusme nainstalovat balíčky ShinyItemAnalysis a swirl!

22/61

Datové typy

- numerická hodnota (numeric)
- celé číslo (integer)
- komplexní číslo (complex)
- logická hodnota (logical)
- textový řetězec (character)
- NA, NULL, NaN

Numerická hodnota

- v R jako numeric
- libovolné $x \in \mathbb{R}$ uložené s danou přesností
- odpovídá datovému typu double s 64 bitovou přesností, který je běžný v jiných jazycích
- např.

```
5; -13.8, 4.5578e15
```

zda je hodnota typu numeric, zjistíme pomocí

```
is.numeric(-13.8)
                         TRUE
class(-13.8)
                        "numeric"
class(Inf)
                         "numeric"
```

vhodná pro různorodé operace (viz dále)



Celé číslo

- v R jako integer
- libovolné $z \in \mathbb{Z}$ uložené s danou přesností
- např.

```
5L; 13L, -5L
```

zda je hodnota typu integer, zjistíme pomocí

```
is.integer(-13L)
                      # TRUE
class(-13L)
                      # "integer"
is.integer(-13)
                     # FALSE
class(-13)
                      # "numeric"
```

přetypování celého čísla na reálné (numeric) pomocí

```
as.numeric(5L)
```

- pozor! v R mají celá čísla pouze 16 bitovou přesnost
- pro práci s velkými celými čísly nutné balíčky gmp či int64 (zvýší bitovou přesnost uložených celých čísel)

Komplexní číslo

- v R jako complex
- libovolné $x \in \mathbb{C}$ takové, že x = a + bi, kde $a, b \in \mathbb{R}$ a $i^2 = -1$
- např.

$$\| 1 + 2i; 0 + 1i \|$$

zda je hodnota typu complex, zjistíme pomocí

```
is.complex(1 + 2i)
                        TRUE
class(0 + 1i)
                 # "complex"
class(sqrt(-1 + 0i)) # "complex"
class(sqrt(-1))
                     # Warning message:
                       # NaNs produced
```

26/61

Logická hodnota

- v R jako logical
- libovolné booleovské $x \in \{TRUE, FALSE\}$
- např.

```
TRUE: FALSE: T: F
```

zda je hodnota typu logical, zjistíme pomocí

```
is.logical(TRUE)
                           TRUE
class(FALSE)
                           "logical"
class("TRUE")
                         # "character"
class(T)
                         # "logical"
class(F)
                           "logical"
```

27/61

Textový řetězec

- v R jako character
- libovolná sekvence znaků (extended ASCII) uzavřená mezi jednoduchými či dvojitými uvozovkami
- např.

```
"ahoj"; 'xweiwogw23425ng'; ""
```

zda je hodnota typu character, zjistíme pomocí

```
is.character("ahoj") # TRUE

class("bla bla") # "character"

class("123") # "character"

class(123) # "numeric"

is.numeric(Inf) # TRUE

is.numeric("Inf") # FALSE
```

na textový řetězec lze převést libovolnou jinou hodnotu pomocí

```
as.character(123)
```

NA, NULL, NaN

- NA je hodnota typu Not Available, obvykle chybějící hodnota
- NULL je null object, používá se pro bezhodnotovou inicializaci objektu (uvidíme později)
- NaN je hodnota typu Not a Number, obvykle nevyjádřitelný výsledek matematické operace
- množinově platí {NaN} ⊂ {NA}
- např.

```
log(-1)
                    # Na.N
is.na(NaN)
                      TRIJF
is.nan(NA)
                    # FALSE
is.nan(1 / 0)
                    # FALSE
1 / 0
                    # Inf
```

Atributy každého objektu

- každý objekt (daného datového typu) má svou třídu a délku
- třída (class) charakterizuje datový typ
- délka (length) vrací počet atomických podobjektů objektu daného datového typu
- např.

```
class("ahoj")
                   # "character"
class(NaN)
                   # "numeric"
class(NA)
                     "logical"
class(class(NA))
                     "character"
length("123")
length (123)
length (NaN)
length(NA)
```

Přiřazení hodnoty k proměnné

přiřadit hodnotu nějaké proměnné lze pomocí jednoduchého rovnítka

$$x = 5$$

nebo pomocí orientované šipky

 anebo pomocí funkce assign(), kde prvním argumentem je název proměnné (tedy textový řetězec) a druhým hodnota

```
assign("x", 5) # analogické k x < -5 \check{c}i x = 5
```

to se hodí zejména u dynamického iterování (viz později)



Intermezzo

 zkusme apriorně (bez ověření v R) vyslovit, o jaké datové typy jde v následujících případech

```
1.8
is.logical(is.numeric(-5000))
sqrt(4)
                    # sqrt() je druhá odmocnina
sqrt(4L)
TRUE
"FALSE"
asin(2)
                    # asin() je arcus sinus
1 / Inf
-2 / INF
class (TRUE)
class(class(is.complex(1 + 1i)))
"357L"
as.integer("357L")
as.integer("357")
length (12)
```

32/61

Datové struktury

- vektor (vector)
- faktor (factor)
- matice (matrix)
- pole (array)
- tabulka dat (data.frame)
- seznam (list)

Tvorba vektorů a základní příkazy

- vektor je jednorozměrný výčet prvků stejného datového typu, nemá orientaci ve smyslu řádek či sloupec
- vektor je objekt typu tuple, tedy zachovává pořadí svých prvků (na rozdíl od objektů typu set)
- lze vytvořit pomocí generické funkce c(), neboli concatenate
- např.

```
c()
               # prázdný vektor
length(c())
c(3, 1, 2)
              # vektor o délce 3 a prvcích 3, 1, 2
c("a", "d")
               # vektor o dél. 2 a prvcích "a", "d"
```

pomocí funkce c() lze vektory i prodlužovat

```
c(c(3, 1, 2), 4) # vektor o prvcich 3, 1, 2, 4
c(3, 1, 2, 4)
                  # zkráceně totéž
```



Tvorba vektorů a základní příkazy

vektor tedy lze prodloužit libovolně o jednu či více hodnot

```
x < -c(3, 1, 2)
length(x)
y <- 1
z < -c(2)
w < -c(5.7)
x <- c(x, y) # prodloužení vektoru x
                   # o hodnotu y
w \leftarrow c(w, z)
                   # prodloužení vektoru w
                   # o vektor z
                   # jednoprvkový vektor je
                   # skalárem, jednou hodnotou
c < -c(1, 2, 3)
                   # vektor o prvcích 1, 2, 3
                   # byť je c referovaný termín,
                   # funkce c je zachována
                   # a vznikl vektor c
```

Vektory textových řetězců

 vektory obsahující textové hodnoty, lze je použít např. jako názvy prvků jiného vektoru

```
x < -c(3, 1, 2)
y <- c("a", "b", "c")
names(x) <- y # pojmenuje prvky
                   # vektoru x
X
unname (x)
                   # zbaví prvky vektoru
                   # x jeho jejich jmen
setNames(x, y)
                   # opět pojmenuje
                   # prvky vektoru x
```

Subvektory, indexování, adresace

 vektor obsahující celočíselnou aritmetickou řadu lze s výhodou vytvořit následovně

```
x <- 1:10 # vektor o prvcích 1, 2, ..., 10
y <- 5:1 # vektor o prvcích 5, 4, ..., 1
z < - seq(from = 2, to = 10, by = 2)
              # vektor o prvcích 2, 4, 6, 8, 10
w < - seq(2, 10, 2)
              # totéž
```

toho lze využít při indexování

• R indexuje vektory od 1, nikoliv od 0 (první prvek má index 1, druhý index 2, apod.)

Subvektory, indexování, adresace

adresujeme pomocí hranatých závorek []

```
x < -c(4, 2, 6,
x[1]
                # c(4, 2)
x[1:2]
x [5]
x[length(x)] # -3
x[c(1, 3, 4)] # c(4, 6, -3)
x[length(x):1] # c(-3, 6, 2, 4)
                 # totéž, c(-3, 6, 2, 4)
rev(x)
```

Logické vektory

používají se (nejen) k adresování vhodných prvků

```
y <- c(TRUE, TRUE, FALSE, TRUE) # loqický
                                  # vektor
x < -c(3, 1, 2, 5)
                      # (sub)vektor c(3, 1)
x [y]
x[c(F, T, F, T)] # subvektor c(1, 5)
```

výhodný je někdy tzv. recycling

```
z <- c("R", "G", "E", "F", "I")
z[c(T, F)] # vybere pouze hodnoty
                # na lichých pozicích,
                # tedy "R", "E", "I"
                # neboli vektor
                # c("R". "E". "I")
```

Intermezzo

vypišme z vektoru x každou třetí a pátou hodnotu

```
x < -c(34, 65, 4, 0, 56, 23, 54, 17,
       4, 8, 5, 44, 84, -5, 4444, 49,
       37, 86, 45, 65, 36, 72, 54, 36,
       56, 74, 26, 88, 36, 76, 46,
       17, 84, 57, 25, -75, 634, 5578,
       -6, 46, 44, 743, 577, 466,
       645, 33, 64, 67)
```

Intermezzo

vypišme z vektoru x každou třetí a pátou hodnotu

```
x < -c(34, 65, 4, 0, 56, 23, 54, 17,
       4, 8, 5, 44, 84, -5, 4444, 49,
       37, 86, 45, 65, 36, 72, 54, 36,
       56, 74, 26, 88, 36, 76, 46,
       17, 84, 57, 25, -75, 634, 5578,
       -6, 46, 44, 743, 577, 466,
       645, 33, 64, 67)
```

řešením může být

```
x[c(F, F, T, F, T)]
        # 4, 56, 17, 8, 84, 4444, 86, 65, 54,
        # 56, 88, 76, 84, 25, 5578, 46, 577,
        # 645, 67
```

Faktory

vektory textových hodnot, kde každá hodnota patří do své kategorie

```
x <- factor(
    c("muž", "žena", "muž", "muž")
          # pořadí kategorií je defaultně
          # abecední
x <- factor(
    c("muž", "žena", "muž", "muž"),
    levels = c("žena", "muž")
         # zde si pořadí kategorií
          # určíme sami
```

nad faktory snadno vytvoříme kontingenční tabulku

```
table(x)
              # žena muž
              # 1 3
```



- Ize je použít jako operátory mezi dvěma (či více) hodnotami, ale i mezi dvěma (či více) vektory shodných délek
- lze užít tzv. prefix notaci ve tvaru 'operátor'(..., ...) vhodnou pro dvnamické iterování
- mezi aritmetické operátory patří

operace	operátor	prefix notace	příklad
sčítání	+	'+'()	2 + 3; '+'(2, 3)
odčítání	-	'-'()	2 - 3; '-'(2, 3)
násobení	*	<pre>'*'()</pre>	2 * 3; '*'(2, 3)
dělení	/	'/'()	2 / 3; '/'(2, 3)
mocnění	^ či **	'^'()	2 ^ 3; '^'(2, 3);
			či 2 ** 3
$modulo^1$	%%	'%%'()	7 %% 3; '%%'(7, 3)
celočíselné			
dělení	%/%	'%/%'()	7 %/% 3; '%/%'(7, 3)

sčítání

```
2 + 3
15 + 25 + 35
                          # 75
c(1, 2) + c(10, 20)
                          # c(11, 22)
'+'(2, 3)
'+'(15, 25, 35)
                          # Error: operator needs
                          # one or two arguments
'+'('+'(15, 25), 35)
                          # 75
'+'(c(1, 2), c(10, 20)) # c(11, 22)
```

odčítání

```
35 - 25 - 15
c(12, 25) - c(3, 6)
                          # c(9, 19)
'-'(12, 3)
'-'(35, 25, 15)
                          # Error: operator needs
                          # one or two arguments
'-'('-'(35, 25), 15)
                          # -5
'-'(c(12, 25), c(3, 6)) # c(9, 19)
```

násobení

```
# 36
35 * 25 * 15
                          # 13125
c(12, 25) * c(3, 6)
                          # c(36, 150)
'*'(12, 3)
                          # 36
'*'(35, 25, 15)
                          # Error: operator needs
                          # one or two arguments
'*'('*'(35, 25), 15) # 13125
'*'(c(12, 25), c(3, 6)) # c(36, 150)
```

dělení

```
45 / 5 / 3
                          \# c(4, 5)
c(12, 25) / c(3, 5)
'/'(12, 3)
'/'(45, 5, 3)
                          # Error: operator needs
                          # one or two arguments
'/'('/'(45, 5), 3)
                          # 3
'/'(c(12, 25), c(3, 5)) # c(4, 5)
```

mocnění

```
2 ** 3
                            # 8; Python-like notace
4 ^ 3 ** 2
                            # 262144
4 ^ (3 ** 2)
                            # 262144
(4^3) ** 2
                            # 4096; pozor na
                            # uzávorkování !!!
c(25, 36) ^ 0.5
                            # c(5, 6); odmocňování
c(5, 3) ^ c(2, 3)
                           \# c(25, 27)
c(5, 3) ** c(2, 3)
                            \# c(25, 27)
'^'(2, 3)
'**'(2, 3)
                            # Error: could not find
                            # function "**"
(~(4, 3, 2)
                            # Error: operator needs
                            # one or two arguments
'^'('^'(4, 3), 2)
                            # 4096
'^'(c(5, 3), c(2, 3))
                           \# c(25, 27)
```

- modulo (zbytek po celočíselném dělení)
 - operace m %% n vrací takové k, aby bylo $\frac{|n|}{n} \cdot k \in \{0, 1, \dots, n-1\}$ a současně $\frac{m-k}{n} \in \mathbb{Z}$, kde $m \in \mathbb{Z}$ a $n \in \mathbb{Z} \setminus \{0\}$ jsou dané parametry
 - formálně též $m \equiv k \pmod{n}$
 - čteme "m je kongruentní s k modulo n"

```
12 %% 3
10 %% 3
10 %% -3
5 %% 0
                            # NaN; n nesmí
                            # být nula !
17 %% 23
                            # 17
```

- celočíselné dělení
 - operace m %/% n vrací takové z, aby platilo m=zn+k a současně $\frac{|n|}{n} \cdot k \in \{0, 1, \dots, n-1\}$, kde $m \in \mathbb{Z}$, $n \in \mathbb{Z} \setminus \{0\}$ jsou dané parametry
 - víme-li tedy, že pro nějaká $m \in \mathbb{Z}$ a $n \in \mathbb{Z} \setminus \{0\}$ je $m \equiv k \pmod{n}$, pak výsledkem celočíselného dělení m %/% n bude $\frac{m-k}{n}$

```
12 %/% 3
10 %/% 3
10 %/% -3
                               # -2
5 %/% 0
                               # Inf
17 %/% 23
23 %/% 17
17 %/% 5
                               # 3; celočíselné
                               # dělení
(17 - 17 \% 5) / 5
                               # 3; explicitní
                               # výpočet
(17 \%/\% 5) * 5 + (17 \%\% 5)
                               # 17
```

- uživatelem definované operátory
 - soubor vestavěných aritmetických operátorů lze rozšířit o vlastní, uživatelem definované operátory (více později u uživatelem-definovaných funkcí)

```
# definuji vlastní operátor
\frac{1}{2}%očaruj_pomocí%' <- function(x, y){x^2 + y}
                              # 5 ^ 2 + 4 = 29
5 %očaruj_pomocí% 4
                                #6^2 - 3 = 33
6 %očaruj_pomocí% -3
# definuji operátor, který vrací TRUE, právě když
# je první číslo celočíselným dělitelem druhého
\frac{1}{2} '%d%' <- function(d, n){n %% d == 0}
3 %d% 9
                                # TRUE
4 %d% 9
                                # FALSE
'%d%'(7, 21)
                                # TRUE; prefix notace
```

Logické operace

- logické operace lze užít obecně nad výroky, tj. nad objekty s datovým typem logical
- operace short AND (operator &)
 - použitelná pro vektory
 - vyhodnocuje všechny výroky vektoru a vrací jejich hodnoty

```
c(FALSE, FALSE, TRUE, TRUE) &
c (FALSE, TRUE, FALSE, TRUE)
               # c(FALSE, FALSE, FALSE, TRUE)
```

- operace long AND (operator &&, ,,AND-AND")
 - použitelná také pro vektory
 - vyhodnocuje pouze nutný počet výroků (možná optimalizace) a vrací ien jednu hodnotu

```
c(FALSE, FALSE, TRUE, TRUE) &&
c(FALSE, TRUE, FALSE, TRUE)
               # FALSE
```

51/61

Logické operace

- operace short OR (operator |)
 - použitelná pro vektory, vyhodnocuje všechny výroky vektoru a vrací iejich hodnoty

```
c(FALSE, FALSE, TRUE, TRUE) |
c (FALSE, TRUE, FALSE, TRUE)
      # c(FALSE, TRUE, TRUE, TRUE)
```

- operace long OR (operator | | , ,,OR-OR")
 - použitelná také pro vektory, vyhodnocuje pouze nutný počet výroků (možná optimalizace) a vrací jen jednu hodnotu

```
c(FALSE, FALSE, TRUE, TRUE) ||
c(FALSE, TRUE, FALSE, TRUE)
      # FALSE, protože první dvojice vrací FALSE
```

operace XOR (funkce xor(), "vylučovací OR")

```
xor(c(FALSE, FALSE, TRUE, TRUE),
    c(FALSE, TRUE, FALSE, TRUE))
      # c(FALSE, TRUE, TRUE, FALSE)
```

Logické operace

- operace NOT (operator !)
 - vrací výroku opačnou logickou hodnotu, než které výrok nabývá

```
! TRUE # FALSE
! 2 > 3 # TRUE
```

- funkce all()
 - vrací pro vektor výroků TRUE právě tehdy, jsou-li všechny výroky rovné TRUE

```
all(c(3 > 2, 7 %% 3 == 1, 1 == 0)) # FALSE
all(c(3 > 2, 7 %% 3 == 1, 1 >= 0)) # TRUE
```

- funkce any()
 - vrací pro vektor výroků TRUE právě tehdy, je-li alespoň jeden z výroků roven TRUE

```
any(c(3 < 2, 7 %% 3 <= 0, FALSE)) # FALSE
any(c(3 > 2, 7 %% 3 >= 1, !FALSE)) # TRUE
```

Operace porovnávání (komparace)

- pomocí operací porovnávání lze srovnat velikost či pořadí dvou objektů stejného datového typu; datový typ může přitom být v podstatě libovolný
- výsledkem operace porovnání je výrok, tedy hodnota datového typu logical
- porovnání typu je rovno (==, all.equal(), identical())

```
2 == 3
                     # FALSE
'=='("a", "a") # TRUE; prefix notace
all.equal(c(1, 2), c(1, 2 + 1e-13),
           tolerance = 1e-12)
                     # TRUE; porovnává vektory
                     # volitelnou danou tolerancí
identical(c(1, 2), c(1, 2 + 1e-13))
                     # FALSE, porovnává objekty
                     # a vrací TRUE jen při úplné
                     # shodě
```

Operace porovnávání (komparace)

 porovnání typu je menší, je menší rovno, je větší, je větší rovno (<, <=, >, >=)

```
2 < 3
                      # TRUE
"b" <= "a"
                      # FALSE; porovnává pořadí
                      # v abecedě
'>'(12, 11)
                      # TRUE; prefix notace
FALSE >= TRUE
                      # FALSE; porovnává hodnotu
                      # v booelovské aritmetice
                       \# (TRUE := 1, FALSE := 0)
```

porovnání typu není rovno, je různé od (!=)

```
TRIJF
TRUE != FALSE
                     # TRUE
'!='(FALSE, FALSE) # FALSE; prefix notace
```



Operace porovnávání (komparace)

porovnání typu je obsaženo ve (%in%)

```
c(2, 6) \%in\% c(1:5)
                            # c(TRUE, FALSE)
"k" %in% LETTERS
                            # FALSE
"J" %in% letters
                            # FALSE
"May" %in% month.name
                            # TRUE
'%in%'("Jan", month.abb)
                            # TRUE; prefix notace
"a" %in% "abeceda"
                            # FALSE
```

ekvivalentem (wrapperem) operace %in% je funkce is.element()

```
is.element(c(2, 6), c(1:5))
                            # c(TRUE, FALSE)
is.element(c(1:5), c(2, 6))
                            # c(FALSE, TRUE,
                            # FALSE, FALSE, FALSE)
```

funkce typu je pravdou (isTRUE())

```
isTRUE(3^2 > 2^3)
                            # TRUE
```

Množinové operace

ullet sjednocení množin typu $A \cup B$

```
union(c(1, 2, 3), c(5, 1)) # c(1, 2, 3, 5)
```

ullet průnik množin typu $A\cap B$

intersect(c(1, 2, 3), c(5, 1)) #
$$c(1)$$

• asymetrický rozdíl množin typu A-B

```
setdiff(c(1, 2, 3), c(5, 1)) # c(2, 3)
```

• symetrický rozdíl množin typu $A \div B = (A - B) \cup (B - A)$

```
union(setdiff(c(1, 2, 3), c(5, 1)),
setdiff(c(5, 1), c(1, 2, 3)))
# c(2, 3, 5)
```

• jsou si množiny rovny, tedy $A \subseteq B \land B \subseteq A \iff A = B$?

```
setequal(c(1, 2, 3), c(5, 1)) # FALSE setequal(c(1, 2, 3), c(3, 2, 1)) # TRUE
```

Vestavěné matematické funkce

- jde o funkce balíčků base, stats a dalších, je jich obrovské množství
- např.

```
abs(), sign()
acos(), asin(), atan()
sin(), cos(), tan()
ceiling(), floor(), trunc()
exp(), log(), log10(), log2(), sqrt()
max(), min(), prod(), sum()
cummax(), cummin(), cumprod(), cumsum(),
   diff()
pmax(), pmin()
range()
mean(), median(), cor(), sd(), var()
rle()
```

Zaokrouhlování, formátování čísel

 zaokrouhlení čísla x pomocí round(x, digits) na digits desetinných míst

```
round(1.4, digits = 0)
round(-146.655, 2)
                            # -146.66
```

 zaokrouhlení čísla x pomocí signif(x, digits) na digits platných cifer

```
signif(1.458, digits = 1) # 1
signif(1.458, digits = 2) # 1.5
signif(1.458, digits = 3) # 1.46
signif(1.458, digits = 4) # 1.458
```

 formátování čísla x pomocí format(x, nsmall) na nsmall fixních desetinných cifer

```
format (1.45, nsmall = 1) # "1.45"
format(1.45, nsmall = 2)
                            # "1.45"
format(1.45, nsmall = 3)
                            # "1.450"
```

59/61

Konstanty

- některé matematické a textové konstanty jsou součástí jádra R
- např.

```
# 3.141593; Ludolfovo číslo
рi
exp(1)
                 # 2.718282; Eulerovo číslo
Inf
                 # nekonečno
-Inf
                 # mínus nekonečno
letters
                 # malá písmena anglické abecedy
LETTERS
                 # velká písmena anglické abecedy
month.name
                 # názvy měsíců
month.abb
                 # zkratky názvů měsíců
weekdays (Sys. Date())
                 # vrátí aktuální den v týdnu
weekdays (seq (as. Date ("2017-10-23"),
               as.Date("2017-10-29"), 1))
                 # vypíše názvy dnů v týdnu
```

fyzikální konstanty jsou dostupné v balíčku constants

Děkuji za pozornost!

lubomir.stepanek@lf1.cuni.cz lubomir.stepanek@fbmi.cvut.cz



github.com/LStepanek/17VSADR Skriptovani a analyza dat v jazyce R