Úvod, instalace R a Rstudia, základní datové typy a struktury operace, čísla, vektory a práce s nimi

—

17VSADR – Skriptování a analýza dat v jazyce R

Lubomír Štěpánek[1, 2]

[1]Oddělení biomedicínské statistiky
Ústav biofyziky a informatiky
1. lékařská fakulta
Univerzita Karlova v Praze

ČVUT FBMI

[2]Katedra biomedicínské informatiky
Fakulta biomedicínského inženýrství
České vysoké učení technické v Praze

Obsah

Organizace předmětu

- volitelný předmět (2 kreditové body)
- zakončen zápočtem
- rozsah 0 + 2 (vyučovacích hodin týdně)
- neoficiální účast na bázi dobrovolnosti vítána

Zápočet

- zápočet bude udělen za
  - alespoň rozumnou účast na cvičeních
  - odevzdání alespoň rozumného množství domácích úkolů

Online supplementum

fakultní stránka předmětu ▸ FBMI

https://predmety.fbmi.cvut.cz/cs/17VSADR

githubí stránka předmětu ▸ GitHub

https://github.com/LStepanek/17VSADR_Skriptovani_a_analyza_dat_v_jazyce_R

Literatura


Karel Zvára. *Základy statistiky v prostředí R*. Praha, Česká republika: Karolinum, 2013. ISBN: 978-80-246-2245-3.


Hadley Wickham. *Advanced R*. Boca Raton, FL: CRC Press, 2015. ISBN: 978-1466586963.

Proč bych se právě já měl učit s R

- s vědou (nejen) v biomedicíně to myslím vážně
- chtěl bych se věnovat postgraduálnímu doktorskému studiu, kde jistojistě budu potřebovat statistiku
- jsem postgraduální student a jednou bych chtěl dokončit postgraduální doktorské studium, k čemuž tu zatracenou statistiku opravdu potřebuji
- jsem lékař a hledám konečně efektivní nástroj pro analýzy svých výzkumů
- komerční statistické programy pro mě nejsou dostupné, nebo nejsou dobře použitelné
- sbírám opakovaně data stejného charakteru a rád bych si jejich (před)zpracování automatizoval

Proč bych se právě já měl učit s R

- publikuji v odborných časopisech a rád bych do statě článku s Methodology and Statistical Analysis pravdivě psal, že „. . . all statistical analyses were performed using R language for statistical computing and graphics. . .“, protože existují důkazy, že citování R či jiných volných statistických nástrojů mnohdy zvyšuje pravděpodobnost citování takového článku
- tuším, že věda 2.0 v biomedicíně se bude provozovat nejen formou experimentů na živém (in vivo) či v laboratořích (in vitro), ale budou ji tvořit ze značné části počítačové modely a simulace (in silico)
- uvědomuji si, že MS Excel v základním rozhraní neumí doteď vykreslit krabicový diagram

Proč bych se právě já měl učit s R

- zpracování dat v tabulkových procesorech a spoléhání se jen na ně je spjato s různými problémy, chybné výstupy z tabulkových procesorů dokonce vyvolaly některé vědecké skandály
- data již nějakou dobu (sám) analyzuji a přemýšlím, který nástroj pro analýzu (s kvalitní dokumentací a živou podporou a komunitou) se začít učit

Co je R

- R je interpretovaný programovací jazyk
- kombinuje několik paradigmat
  - imperativní
  - funkcionální
  - objektové
- R je *domain specific language* – je určen pro statistickou analýzu dat a jejich grafické zobrazení
- R je open-source, konkrétně *free-as-in-beer* a *free-as-in-speech*

Stručná historie R

- R vychází z jazyka a prostředí S, které vyvinuto v Bellových laboratořích v letech 1975-1976 (prof. Johne Chambers)
- přerod v R v roce 1992 na Acklandské univerzitě na Novém Zélandu (prof. Ross Ihaka a Robert Gentleman)
- R je tedy akcentem S
- v roce 1994 první verze prostředí R pro volné použití, poté postupně vzniká řada dalších verzí, v září 2017 poslední verze R 3.4.3 („Short Summer“)
- za otce moderního R považován Hadley Wickham (leader analyst v RStudiu, adj. prof. na Aucklandské univerzitě)

Stažení a instalace jádra R

- na stránkách R-projectu

  https://www.r-project.org/

  postupně **download R**, vyberme českou doménu a stáhněme desktopově
- poté instalujme dle instrukcí do předvolené složky

Stažení a instalace RStudia

- RStudio je jedním z grafických IDE (Integrated Development Environment) jazyka R
- na stránkách RStudia

https://www.rstudio.com/

postupně **Products** > **RStudio** > **Desktop** > **Open Source Edition** > **Free** > **Download**, stáhněme desktopově

- poté instalujme dle instrukcí do předvolené složky

Další software

- může (a bude) se časem hodit i
  - obecný textový editor, např. Notepad++

https://notepad-plus-plus.org/

  - univerzální konvertor dokumentů Pandoc

https://pandoc.org/

  - typografický sázeč TEX

https://miktex.org/

První spuštění R jádra

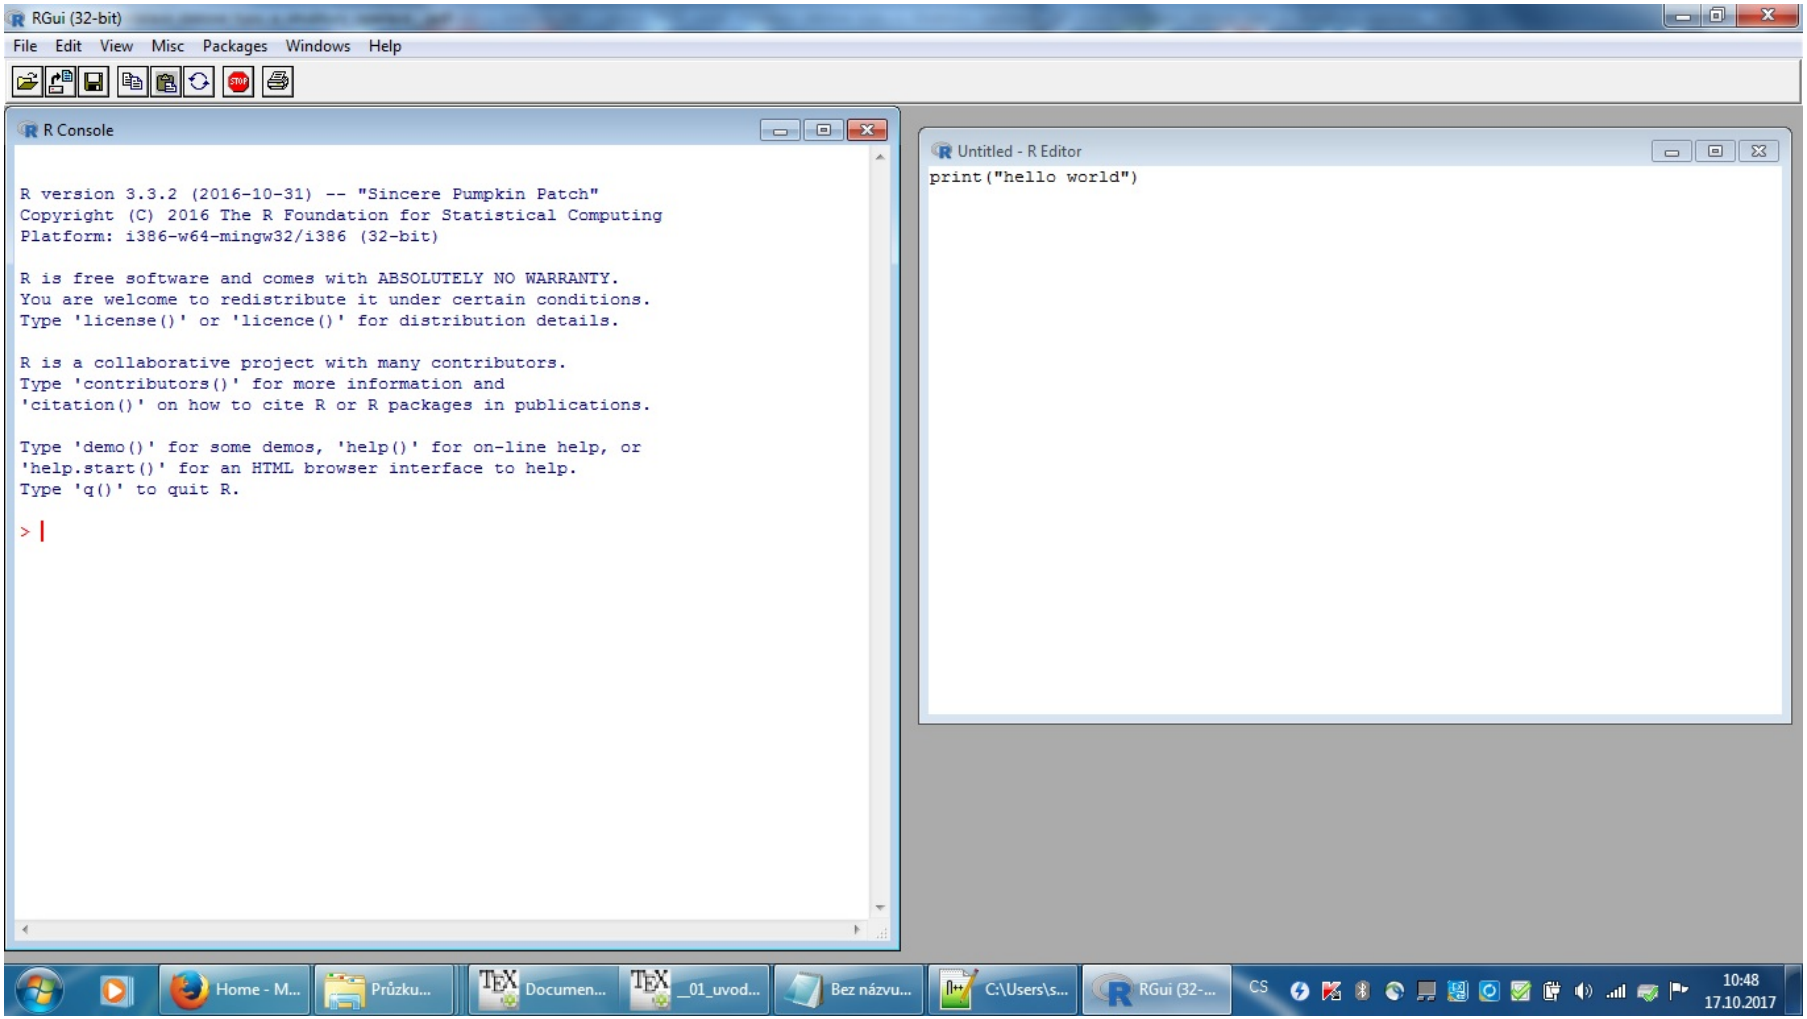

První spuštění RStudia

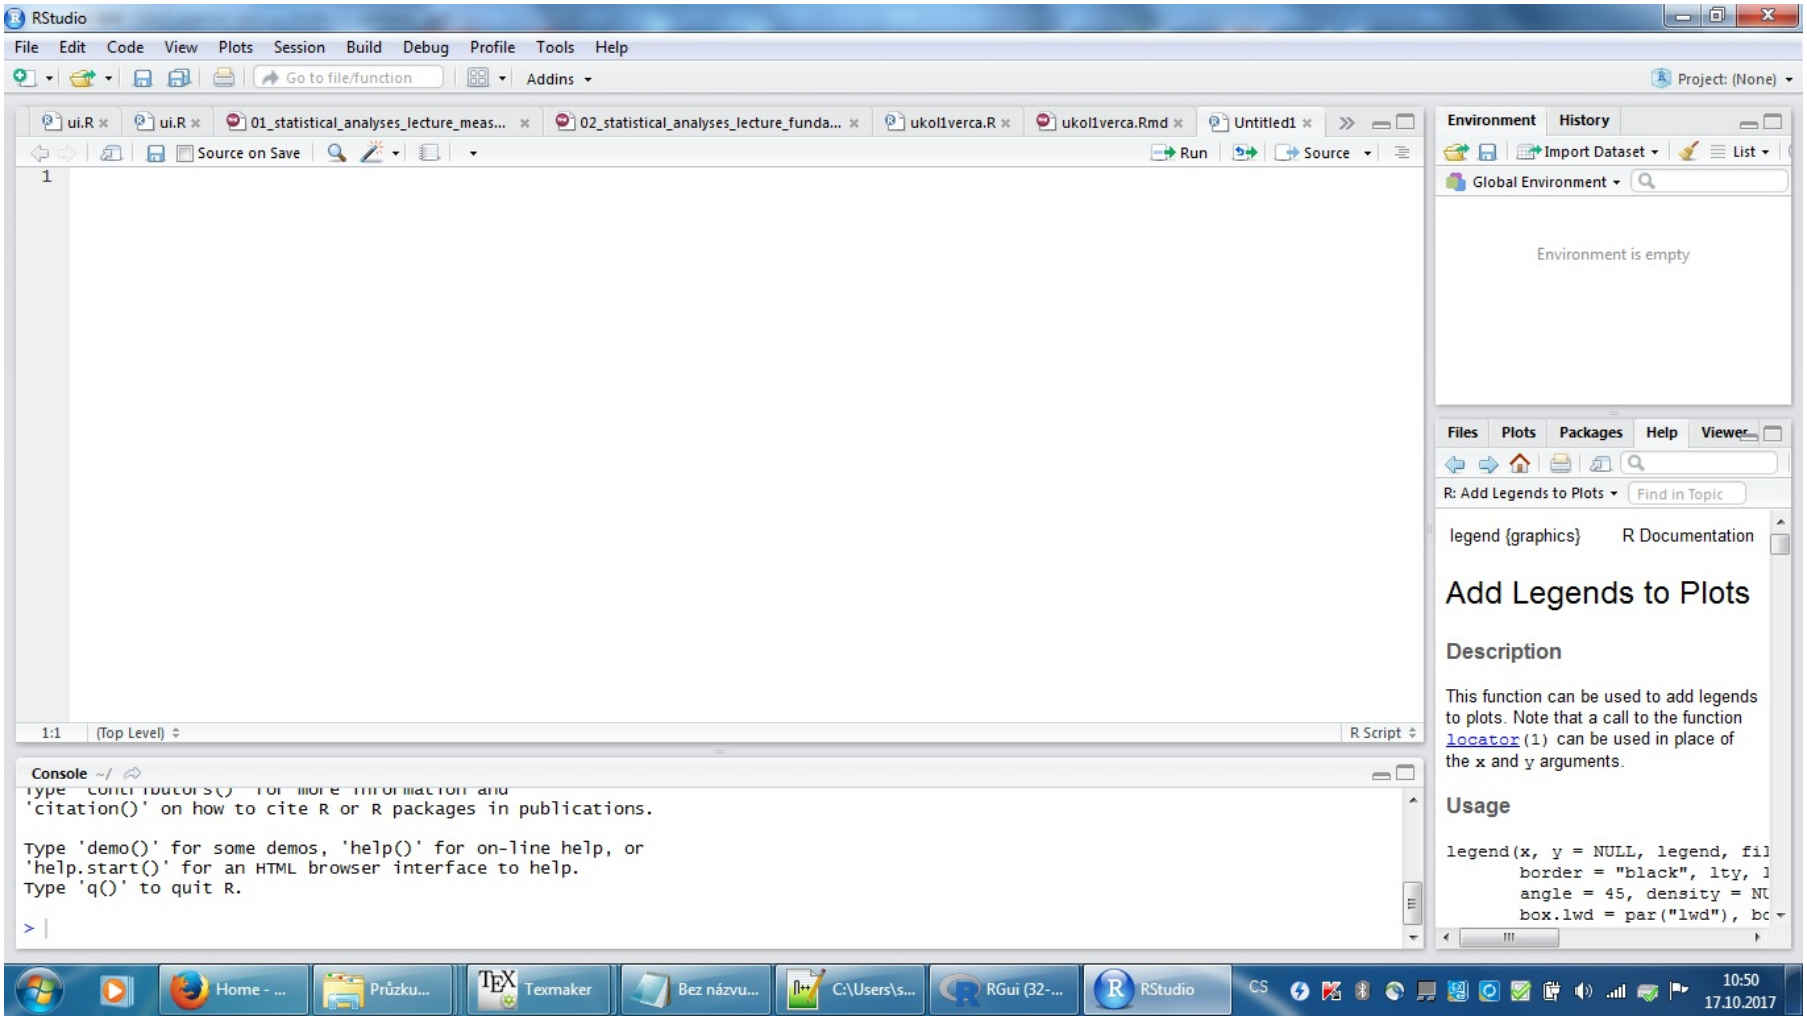

Ahoj světe!

- do skriptu či konzole napišme

```
1 print("hello world")
```

- dostaneme

```
1 [1] "hello world"
```

Práce s nápovědou

- nápovědu pro funkci či objekt získáme pomocí příkazu `help()`, kde argumentem je název funkce či objektu

```
help(print)
```

- nebo předsazením symbolu `?` před název funkce či objektu

```
?print
```

- předsazením symbolů `??` před název funkce či objektu prohledáme veškeré dokumenty nápovědy

```
??print
```

- vždy je zavolán HTML soubor s volnotextovou nápovědou

Přístup k práci v R

1. interaktivní práce mezi skriptem a konzolí (*shell programming*)
2. (dávkové) volání skriptů
   (i) vytvoření funkčního skriptu s příponou `.R`
   (ii) uložení skriptu do pracovní složky, kterou zjistíme pomocí příkazu `getwd()`
   (iii) zavolání a exekuce skriptu v konzoli pomocí příkazu `source(nazev_skriptu.R)`

Intermezzo

1. uložme následující kód jako `scitam_dve_cisla.R`

```
a = 3
b = 4
print(a + b)
```

2. skript `scitam_dve_cisla.R` přesuňme do složky, kterou vrátí příkaz

```
getwd()
```

anebo vhodně nastavme pracovní složku pomocí příkazu

```
setwd(choose.dir())
```

3. do konzole nyní napišme

```
source("scitam_dve_cisla.R")
```

Instalace nadstavbových balíčků

- nejlépe pomocí příkazu

```
1       install.packages(
2           "nazev_balicku",
3           dependencies = TRUE,
4           repos = "http://cran.us.r-project.org"
5       )
```

- poslední argument `repos` není nutný, ale je šikovný, vybere doménu, z které balíček stáhnout, aniž by ji musel uživatel vybrat kliknutím v pop-up okně (vhodné pro úplnou automatizaci kódu)
- zkusme nainstalovat balíčky `ShinyItemAnalysis` a `swirl`!

Datové typy

- numerická hodnota (`numeric`)
- celé číslo (`integer`)
- komplexní číslo (`complex`)
- logická hodnota (`logical`)
- textový řetězec (`character`)
- `NA`, `NULL`, `NaN`

Numerická hodnota

- v R jako `numeric`
- libovolné $x \in \mathbb{R}$ uložené s danou přesností
- odpovídá datovému typu `double` s 64 bitovou přesností, který je běžný v jiných jazycích
- např.

```
5; -13.8, 4.5578e15
```

- zda je hodnota typu `numeric`, zjistíme pomocí

```
is.numeric(-13.8)     # TRUE
class(-13.8)          # "numeric"
class(Inf)            # "numeric"
```

- vhodná pro různorodé operace (viz dále)

Celé číslo

- v R jako `integer`
- libovolné $z \in \mathbb{Z}$ uložené s danou přesností
- např.

```
5L; 13L, -5L
```

- zda je hodnota typu `integer`, zjistíme pomocí

```
is.integer(-13L)     # TRUE
class(-13L)          # "integer"
is.integer(-13)      # FALSE
class(-13)           # "numeric"
```

- přetypování celého čísla na reálné (`numeric`) pomocí

```
as.numeric(5L)
```

- pozor! v R mají celá čísla pouze 16 bitovou přesnost
- pro práci s velkými celými čísly nutné balíčky `gmp` či `int64` (zvýší bitovou přesnost uložených celých čísel)

Komplexní číslo

- v R jako `complex`
- libovolné $x \in \mathbb{C}$ takové, že $x = a + bi$, kde $a, b \in \mathbb{R}$ a $i^2 = -1$
- např.

```
1 ||        1 + 2i; 0 + 1i
```

- zda je hodnota typu `complex`, zjistíme pomocí

```
1 ||        is.complex(1 + 2i)     # TRUE
2 ||        class(0 + 1i)          # "complex"
3 ||        class(sqrt(-1 + 0i))   # "complex"
4 ||        class(sqrt(-1))        # Warning message:
5 ||                               # NaNs produced
```

Logická hodnota

- v R jako `logical`
- libovolné booleovské $x \in \{\texttt{TRUE}, \texttt{FALSE}\}$
- např.

```
1 ||      TRUE; FALSE; T; F
```

- zda je hodnota typu `logical`, zjistíme pomocí

```
1 ||      is.logical(TRUE)        # TRUE
2 ||      class(FALSE)            # "logical"
3 ||      class("TRUE")           # "character"
4 ||      class(T)                # "logical"
5 ||      class(F)                # "logical"
```

Textový řetězec

- v R jako `character`
- libovolná sekvence znaků (extended ASCII) uzavřená mezi jednoduchými či dvojitými uvozovkami
- např.

```
"ahoj"; 'xweiwogw23425ng'; ""
```

- zda je hodnota typu `character`, zjistíme pomocí

```
is.character("ahoj")   # TRUE
class("bla bla")       # "character"
class("123")           # "character"
class(123)             # "numeric"
is.numeric(Inf)        # TRUE
is.numeric("Inf")      # FALSE
```

- na textový řetězec lze převést libovolnou jinou hodnotu pomocí

```
as.character(123)
```

NA, NULL, NaN

- NA je hodnota typu Not Available, obvykle chybějící hodnota
- NULL je null object, používá se pro bezhodnotovou inicializaci objektu (uvidíme později)
- NaN je hodnota typu Not a Number, obvykle nevyjádřitelný výsledek matematické operace
- množinově platí $\{\texttt{NaN}\} \subset \{\texttt{NA}\}$
- např.

```
1  log(-1)              # NaN
2  is.na(NaN)           # TRUE
3  is.nan(NA)           # FALSE
4  is.nan(1 / 0)        # FALSE
5  1 / 0                # Inf
```

Atributy každého objektu

- každý objekt (daného datového typu) má svou třídu a délku
- třída (`class`) charakterizuje datový typ
- délka (`length`) vrací počet atomických podobjektů objektu daného datového typu
- např.

```
1        class("ahoj")      # "character"
2        class(NaN)         # "numeric"
3        class(NA)          # "logical"
4        class(class(NA))   # "character"
5        length("123")      # 1
6        length(123)        # 1
7        length(NaN)        # 1
8        length(NA)         # 1
```

Přiřazení hodnoty k proměnné

- přiřadit hodnotu nějaké proměnné lze pomocí jednoduchého rovnítka

```
1 |       x = 5
```

- nebo pomocí orientované šipky

```
1 |       x <- 5
2 |       5 -> x       # totéž
```

- anebo pomocí funkce `assign()`, kde prvním argumentem je název proměnné (tedy textový řetězec) a druhým hodnota

```
1 |       assign("x", 5)   # analogické k x <- 5 či x = 5
```

to se hodí zejména u dynamického iterování (viz později)

Intermezzo

- zkusme apriorně (bez ověření v R) vyslovit, o jaké datové typy jde v následujících případech

```
1.8
is.logical(is.numeric(-5000))
sqrt(4)                 # sqrt() je druhá odmocnina
sqrt(4L)
TRUE
"FALSE"
asin(2)                 # asin() je arcus sinus
1 / Inf
-2 / INF
class(TRUE)
class(class(is.complex(1 + 1i)))
"357L"
as.integer("357L")
as.integer("357")
length(12)
```

Datové struktury

- vektor (`vector`)
- faktor (`factor`)
- matice (`matrix`)
- pole (`array`)
- tabulka dat (`data.frame`)
- seznam (`list`)

Tvorba vektorů a základní příkazy

- vektor je jednorozměrný výčet prvků stejného datového typu, nemá orientaci ve smyslu řádek či sloupec
- vektor je objekt typu *tuple*, tedy zachovává pořadí svých prvků (na rozdíl od objektů typu *set*)
- lze vytvořit pomocí generické funkce `c()`, neboli *concatenate*
- např.

```
c()              # prázdný vektor
length(c())      # 0
c(3, 1, 2)       # vektor o délce 3 a prvcích 3, 1, 2
c("a", "d")      # vektor o dél. 2 a prvcích "a", "d"
```

- pomocí funkce `c()` lze vektory i prodlužovat

```
c(c(3, 1, 2), 4) # vektor o prvcích 3, 1, 2, 4
c(3, 1, 2, 4)    # zkráceně totéž
```

Tvorba vektorů a základní příkazy

- vektor tedy lze prodloužit libovolně o jednu či více hodnot

```
1   x <- c(3, 1, 2)
2   length(x)           # 3
3   y <- 1
4   z <- c(2)
5   w <- c(5, 7)
6   x <- c(x, y)        # prodloužení vektoru x
7                       # o hodnotu y
8   w <- c(w, z)        # prodloužení vektoru w
9                       # o vektor z
10                      # jednoprvkový vektor je
11                      # skalárem, jednou hodnotou
12  c <- c(1, 2, 3)
13  c                   # vektor o prvcích 1, 2, 3
14                      # byť je c referovaný termín,
15                      # funkce c je zachována
16                      # a vznikl vektor c
```

Vektory textových řetězců

- vektory obsahující textové hodnoty, lze je použít např. jako názvy prvků jiného vektoru

```
1  x <- c(3, 1, 2)
2  y <- c("a", "b", "c")
3  names(x) <- y      # pojmenuje prvky
4                     # vektoru x
5  x
6  unname(x)          # zbaví prvky vektoru
7                     # x jeho jejich jmen
8  setNames(x, y)     # opět pojmenuje
9                     # prvky vektoru x
```

Subvektory, indexování, adresace

- vektor obsahující celočíselnou aritmetickou řadu lze s výhodou vytvořit následovně

```
1       x <- 1:10       # vektor o prvcích 1, 2, ..., 10
2       y <- 5:1        # vektor o prvcích 5, 4, ..., 1
3       z <- seq(from = 2, to = 10, by = 2)
4                       # vektor o prvcích 2, 4, 6, 8, 10
5       w <- seq(2, 10, 2)
6                       # totéž
```

toho lze využít při indexování

- R indexuje vektory od 1, nikoliv od 0 (první prvek má index 1, druhý index 2, apod.)

Subvektory, indexování, adresace

- adresujeme pomocí hranatých závorek [ ]

```
1  x <- c(4, 2, 6, -3)
2  x[1]                # 4
3  x[1:2]              # c(4, 2)
4  x[5]                # NA
5  x[length(x)]        # -3
6  x[c(1, 3, 4)]       # c(4, 6, -3)
7  x[length(x):1]      # c(-3, 6, 2, 4)
8  rev(x)              # totéž, c(-3, 6, 2, 4)
```

Logické vektory

- používají se (nejen) k adresování vhodných prvků

```
y <- c(TRUE, TRUE, FALSE, TRUE) # logický
                                # vektor
x <- c(3, 1, 2, 5)
x[y]                        # (sub)vektor c(3, 1)
x[c(F, T, F, T)]            # subvektor c(1, 5)
```

- výhodný je někdy tzv. *recycling*

```
z <- c("R", "G", "E", "F", "I")
z[c(T, F)]      # vybere pouze hodnoty
                # na lichých pozicích,
                # tedy "R", "E", "I"
                # neboli vektor
                # c("R", "E", "I")
```

Intermezzo

- vypišme z vektoru `x` každou třetí a pátou hodnotu

```
x <- c(34, 65, 4, 0, 56, 23, 54, 17,
       4, 8, 5, 44, 84, -5, 4444, 49,
       37, 86, 45, 65, 36, 72, 54, 36,
       56, 74, 26, 88, 36, 76, 46,
       17, 84, 57, 25, -75, 634, 5578,
       -6, 46, 44, 743, 577, 466,
       645, 33, 64, 67)
```

Intermezzo

- vypišme z vektoru `x` každou třetí a pátou hodnotu

```
x <- c(34, 65, 4, 0, 56, 23, 54, 17,
       4, 8, 5, 44, 84, -5, 4444, 49,
       37, 86, 45, 65, 36, 72, 54, 36,
       56, 74, 26, 88, 36, 76, 46,
       17, 84, 57, 25, -75, 634, 5578,
       -6, 46, 44, 743, 577, 466,
       645, 33, 64, 67)
```

- řešením může být

```
x[c(F, F, T, F, T)]

       # 4, 56, 17, 8, 84, 4444, 86, 65, 54,
       # 56, 88, 76, 84, 25, 5578, 46, 577,
       # 645, 67
```

Faktory

- vektory textových hodnot, kde každá hodnota patří do své kategorie

```
x <- factor(
    c("muž", "žena", "muž", "muž")
)           # pořadí kategorií je defaultně
            # abecední
x <- factor(
    c("muž", "žena", "muž", "muž"),
    levels = c("žena", "muž")
)           # zde si pořadí kategorií
            # určíme sami
```

- nad faktory snadno vytvoříme kontingenční tabulku

```
table(x)    # x
            # žena muž
            # 1 3
```

Aritmetické operace

- lze je použít jako operátory mezi dvěma (či více) hodnotami, ale i mezi dvěma (či více) vektory shodných délek
- lze užít tzv. *prefix notaci* ve tvaru `‘operátor‘(..., ...)` vhodnou pro dynamické iterování
- mezi aritmetické operátory patří

operace	operátor	prefix notace	příklad
sčítání	`+`	`‘+‘(...)`	`2 + 3; ‘+‘(2, 3)`
odčítání	`-`	`‘-‘(...)`	`2 - 3; ‘-‘(2, 3)`
násobení	`*`	`‘*‘(...)`	`2 * 3; ‘*‘(2, 3)`
dělení	`/`	`‘/‘(...)`	`2 / 3; ‘/‘(2, 3)`
mocnění	`^` či `**`	`‘^‘(...)`	`2 ^ 3; ‘^‘(2, 3); či 2 ** 3`
modulo[1]	`%%`	`‘%%‘(...)`	`7 %% 3; ‘%%‘(7, 3)`
celočíselné dělení	`%/%`	`‘%/%‘(...)`	`7 %/% 3; ‘%/%‘(7, 3)`

Aritmetické operace

- sčítání

```
2 + 3                          # 5
15 + 25 + 35                   # 75
c(1, 2) + c(10, 20)            # c(11, 22)
`+`(2, 3)                      # 5
`+`(15, 25, 35)                # Error: operator needs
                               # one or two arguments
`+`(`+`(15, 25), 35)           # 75
`+`(c(1, 2), c(10, 20))        # c(11, 22)
```

Aritmetické operace

- odčítání

```
12 - 3                          # 9
35 - 25 - 15                    # -5
c(12, 25) - c(3, 6)             # c(9, 19)
`-`(12, 3)                      # 9
`-`(35, 25, 15)                 # Error: operator needs
                                # one or two arguments
`-`(`-`(35, 25), 15)            # -5
`-`(c(12, 25), c(3, 6))         # c(9, 19)
```

Aritmetické operace

- násobení

```
12 * 3                          # 36
35 * 25 * 15                    # 13125
c(12, 25) * c(3, 6)             # c(36, 150)
`*`(12, 3)                      # 36
`*`(35, 25, 15)                 # Error: operator needs
                                # one or two arguments
`*`(`*`(35, 25), 15)            # 13125
`*`(c(12, 25), c(3, 6))         # c(36, 150)
```

Aritmetické operace

- dělení

```
12 / 3                          # 4
45 / 5 / 3                      # 3
c(12, 25) / c(3, 5)             # c(4, 5)
`/`(12, 3)                      # 4
`/`(45, 5, 3)                   # Error: operator needs
                                # one or two arguments
`/`(`/`(45, 5), 3)              # 3
`/`(c(12, 25), c(3, 5))         # c(4, 5)
```

Aritmetické operace

- mocnění

```
2 ^ 3                          # 8
2 ** 3                         # 8; Python-like notace
4 ^ 3 ** 2                     # 262144
4 ^ (3 ** 2)                   # 262144
(4 ^ 3) ** 2                   # 4096; pozor na
                               # uzávorkování !!!
c(25, 36) ^ 0.5                # c(5, 6); odmocňování
c(5, 3) ^ c(2, 3)              # c(25, 27)
c(5, 3) ** c(2, 3)             # c(25, 27)
`^`(2, 3)                      # 8
`**`(2, 3)                     # Error: could not find
                               # function "**"
`^`(4, 3, 2)                   # Error: operator needs
                               # one or two arguments
`^`(`^`(4, 3), 2)              # 4096
`^`(c(5, 3), c(2, 3))          # c(25, 27)
```

Aritmetické operace

- modulo (zbytek po celočíselném dělení)
  - operace m %% n vrací takové k, aby bylo $\frac{|n|}{n} \cdot k \in \{0, 1, \ldots, n-1\}$ a současně $\frac{m-k}{n} \in \mathbb{Z}$, kde $m \in \mathbb{Z}$ a $n \in \mathbb{Z} \setminus \{0\}$ jsou dané parametry
  - formálně též $m \equiv k \pmod{n}$
    - čteme „m je kongruentní s k modulo n“

```
12 %% 3          # 0
10 %% 3          # 1
10 %% -3         # -2
5 %% 0           # NaN; n nesmí
                 # být nula !
17 %% 23         # 17
```

Aritmetické operace

- celočíselné dělení
  - operace m %/% n vrací takové z, aby platilo $m = zn + k$ a současně $\frac{|n|}{n} \cdot k \in \{0, 1, \ldots, n-1\}$, kde $m \in \mathbb{Z}$, $n \in \mathbb{Z} \setminus \{0\}$ jsou dané parametry
  - víme-li tedy, že pro nějaká $m \in \mathbb{Z}$ a $n \in \mathbb{Z} \setminus \{0\}$ je $m \equiv k \pmod{n}$, pak výsledkem celočíselného dělení m %/% n bude $\frac{m-k}{n}$

```
12 %/% 3                          # 4
10 %/% 3                          # 3
10 %/% -3                         # -2
5 %/% 0                           # Inf
17 %/% 23                         # 0
23 %/% 17                         # 1
17 %/% 5                          # 3; celočíselné
                                  # dělení
(17 - 17 %% 5) / 5                # 3; explicitní
                                  # výpočet
(17 %/% 5) * 5 + (17 %% 5)        # 17
```

Aritmetické operace

- uživatelem definované operátory
  - soubor vestavěných aritmetických operátorů lze rozšířit o vlastní, uživatelem definované operátory (více později u uživatelem-definovaných funkcí)

```
1  # definuji vlastní operátor
2  '%očaruj_pomocí%' <- function(x, y){x^2 + y}
3
4  5 %očaruj_pomocí% 4          # 5 ^ 2 + 4 = 29
5  6 %očaruj_pomocí% -3         # 6 ^ 2 - 3 = 33
6
7  # definuji operátor, který vrací TRUE, právě když
8  # je první číslo celočíselným dělitelem druhého
9  '%d%' <- function(d, n){n %% d == 0}
10
11 3 %d% 9                      # TRUE
12 4 %d% 9                      # FALSE
13 `%d%`(7, 21)                 # TRUE; prefix notace
```

Logické operace

- logické operace lze užít obecně nad výroky, tj. nad objekty s datovým typem `logical`
- operace *short* AND (operátor `&`)
  - použitelná pro vektory
  - vyhodnocuje všechny výroky vektoru a vrací jejich hodnoty

```
1  c(FALSE, FALSE, TRUE, TRUE) &
2  c(FALSE, TRUE, FALSE, TRUE)
3                    # c(FALSE, FALSE, FALSE, TRUE)
```

- operace *long* AND (operátor `&&`, „AND-AND“)
  - použitelná také pro vektory
  - vyhodnocuje pouze nutný počet výroků (možná optimalizace) a vrací jen jednu hodnotu

```
1  c(FALSE, FALSE, TRUE, TRUE) &&
2  c(FALSE, TRUE, FALSE, TRUE)
3                    # FALSE
```

Logické operace

- operace *short* OR (operátor |)
  - použitelná pro vektory, vyhodnocuje všechny výroky vektoru a vrací jejich hodnoty

```
c(FALSE, FALSE, TRUE, TRUE) |
c(FALSE, TRUE, FALSE, TRUE)
      # c(FALSE, TRUE, TRUE, TRUE)
```

- operace *long* OR (operátor ||, „OR-OR“)
  - použitelná také pro vektory, vyhodnocuje pouze nutný počet výroků (možná optimalizace) a vrací jen jednu hodnotu

```
c(FALSE, FALSE, TRUE, TRUE) ||
c(FALSE, TRUE, FALSE, TRUE)
      # FALSE, protože první dvojice vrací FALSE
```

- operace XOR (funkce `xor()`, „vylučovací OR“)

```
xor(c(FALSE, FALSE, TRUE, TRUE),
    c(FALSE, TRUE, FALSE, TRUE))
      # c(FALSE, TRUE, TRUE, FALSE)
```

Logické operace

- operace NOT (operátor `!`)
  - vrací výroku opačnou logickou hodnotu, než které výrok nabývá

```
! TRUE                    # FALSE
! 2 > 3                   # TRUE
```

- funkce `all()`
  - vrací pro vektor výroků TRUE právě tehdy, jsou-li všechny výroky rovné TRUE

```
all(c(3 > 2, 7 %% 3 == 1, 1 == 0))   # FALSE
all(c(3 > 2, 7 %% 3 == 1, 1 >= 0))   # TRUE
```

- funkce `any()`
  - vrací pro vektor výroků TRUE právě tehdy, je-li alespoň jeden z výroků roven TRUE

```
any(c(3 < 2, 7 %% 3 <= 0, FALSE))    # FALSE
any(c(3 < 2, 7 %% 3 >= 1, FALSE))    # TRUE
```

Operace porovnávání (komparace)

- pomocí operací porovnávání lze srovnat velikost či pořadí dvou objektů stejného datového typu; datový typ může přitom být v podstatě libovolný
- výsledkem operace porovnání je výrok, tedy hodnota datového typu `logical`
- porovnání typu *je rovno* (==, `all.equal()`, `identical()`)

```
2 == 3                          # FALSE
`==`("a", "a")                  # TRUE; prefix notace
all.equal(c(1, 2), c(1, 2 + 1e-13),
          tolerance = 1e-12)
                                # TRUE; porovnává vektory
                                # volitelnou danou tolerancí
identical(c(1, 2), c(1, 2 + 1e-13))
                                # FALSE, porovnává objekty
                                # a vrací TRUE jen při úplné
                                # shodě
```

Operace porovnávání (komparace)

- porovnání typu *je menší*, *je menší rovno*, *je větší*, *je větší rovno* (<, <=, >, >=)

```
2 < 3                    # TRUE
"b" <= "a"               # FALSE; porovnává pořadí
                         # v abecedě
`>`(12, 11)              # TRUE; prefix notace
FALSE >= TRUE            # FALSE; porovnává hodnotu
                         # v booelovské aritmetice
                         # (TRUE := 1, FALSE := 0)
```

- porovnání typu *není rovno*, *je různé od* (!=)

```
2 != 3                   # TRUE
TRUE != FALSE            # TRUE
`!=`(FALSE, FALSE)       # FALSE; prefix notace
```

Operace porovnávání (komparace)

- porovnání typu *je obsaženo ve* (%in%)

```
c(2, 6) %in% c(1:5)          # c(TRUE, FALSE)
"k" %in% LETTERS             # FALSE
"J" %in% letters             # FALSE
"May" %in% month.name        # TRUE
`%in%`("Jan", month.abb)     # TRUE; prefix notace
"a" %in% "abeceda"           # FALSE
```

- ekvivalentem (wrapperem) operace %in% je funkce `is.element()`

```
is.element(c(2, 6), c(1:5))
                             # c(TRUE, FALSE)
is.element(c(1:5), c(2, 6))
                             # c(FALSE, TRUE,
                             # FALSE, FALSE, FALSE)
```

- funkce typu *je pravdou* (`isTRUE()`)

```
isTRUE(3^2 > 2^3)            # TRUE
```

Množinové operace

- sjednocení množin typu $A \cup B$

```
union(c(1, 2, 3), c(5, 1))          # c(1, 2, 3, 5)
```

- průnik množin typu $A \cap B$

```
intersect(c(1, 2, 3), c(5, 1))      # c(1)
```

- asymetrický rozdíl množin typu $A - B$

```
setdiff(c(1, 2, 3), c(5, 1))        # c(2, 3)
```

- symetrický rozdíl množin typu $A \div B = (A - B) \cup (B - A)$

```
union(setdiff(c(1, 2, 3), c(5, 1)),
      setdiff(c(5, 1), c(1, 2, 3)))
                                    # c(2, 3, 5)
```

- jsou si množiny rovny, tedy $A \subseteq B \wedge B \subseteq A \iff A = B$?

```
setequal(c(1, 2, 3), c(5, 1))       # FALSE
setequal(c(1, 2, 3), c(3, 2, 1))    # TRUE
```

Vestavěné matematické funkce

- jde o funkce balíčků `base`, `stats` a dalších, je jich obrovské množství
- např.

```
1  abs(), sign()
2  acos(), asin(), atan()
3  sin(), cos(), tan()
4  ceiling(), floor(), trunc()
5  exp(), log(), log10(), log2(), sqrt()
6  max(), min(), prod(), sum()
7  cummax(), cummin(), cumprod(), cumsum(),
       diff()
8  pmax(), pmin()
9  range()
10 mean(), median(), cor(), sd(), var()
11 rle()
```

Zaokrouhlování, formátování čísel

- zaokrouhlení čísla `x` pomocí `round(x, digits)` na `digits` desetinných míst

```
round(1.4, digits = 0)        # 1
round(-146.655, 2)            # -146.66
```

- zaokrouhlení čísla `x` pomocí `signif(x, digits)` na `digits` platných cifer

```
signif(1.458, digits = 1)     # 1
signif(1.458, digits = 2)     # 1.5
signif(1.458, digits = 3)     # 1.46
signif(1.458, digits = 4)     # 1.458
```

- formátování čísla `x` pomocí `format(x, nsmall)` na `nsmall` fixních desetinných cifer

```
format(1.45, nsmall = 1)      # "1.45"
format(1.45, nsmall = 2)      # "1.45"
format(1.45, nsmall = 3)      # "1.450"
```

Konstanty

- některé matematické a textové konstanty jsou součástí jádra R
- např.

```
pi                  # 3.141593; Ludolfovo číslo
exp(1)              # 2.718282; Eulerovo číslo
Inf                 # nekonečno
-Inf                # mínus nekonečno
letters             # malá písmena anglické abecedy
LETTERS             # velká písmena anglické abecedy
month.name          # názvy měsíců
month.abb           # zkratky názvů měsíců
weekdays(Sys.Date())
                    # vrátí aktuální den v týdnu
weekdays(seq(as.Date("2018-10-01"),
             as.Date("2018-10-07"), 1))
                    # vypíše názvy dnů v týdnu
```

- fyzikální konstanty jsou dostupné v balíčku `constants`

Děkuji za pozornost!

lubomir.stepanek@lf1.cuni.cz
lubomir.stepanek@fbmi.cvut.cz

▸ GitHub

github.com/LStepanek/17VSADR_Skriptovani_a_analyza_dat_v_jazyce_R