Úvod, instalace R a Rstudia, základní datové typy a struktury, operace

17VSADR – Skriptování a analýza dat v jazyce R

Lubomír Štěpánek^{1, 2}



¹Oddělení biomedicínské statistiky Ústav biofyziky a informatiky 1. lékařská fakulta Univerzita Karlova v Praze



²Katedra biomedicínské informatiky Fakulta biomedicínského inženýrství České vysoké učení technické v Praze

(2020) Lubomír Štěpánek, CC BY-NC-ND 3.0 (CZ)



Lubomír Štěpánek

Dílo lze dále svobodně šířit, ovšem s uvedením původního autora a s uvedením původní licence. Dílo není možné šířit komerčně ani s ním jakkoliv jinak nakládat pro účely komerčního zisku. Dílo nesmí být jakkoliv upravováno. Autor neručí za správnost informací uvedených kdekoliv v předložené práci, přesto vynaložil nezanedbatelné úsilí, aby byla uvedená fakta správná a aktuální, a práci sepsal podle svého nejlepšího vědomí a svých "nejlepších" znalostí problematiky.

ÚvodZačínámeDatové typyDatové strukturyVektoryOperaceMaticeDatové tabulkySeznamy000

Obsah

- Úvod
- Začínáme
- 3 Datové typy
- Datové struktury
- Vektory
- Operace
- Matice
- Oatové tabulky
- Seznamy



Úvod Datové struktury Vektory Datové tabulky Začínáme Datové typy Operace Matice Seznamy •000000 0<u>000</u>

Organizace předmětu

- volitelný předmět (2 kreditové body)
- zakončen zápočtem
- rozsah 0 + 2 (vyučovacích hodin týdně)
- neoficiální účast na bázi dobrovolnosti vítána

4/56

Datové struktury Vektory Datové tabulky Začínáme Datové typy Operace Matice Seznamy 000000 0000

Zápočet

Úvod

- zápočet bude udělen za
 - alespoň rozumnou účast na cvičeních
 - odevzdání alespoň rozumného množství domácích úkolů

Úvod Datové struktury Datové tabulky Začínáme Datové typy Vektory Operace Matice Seznamy 0000000 0000

Online supplementum

fakultní stránka předmětu ▶ FBMI

https://predmety.fbmi.cvut.cz/cs/17VSADR

githubí stránka předmětu ▶ GitHub

https://github.com/LStepanek/17VSADR Skriptovani a analyza dat v jazyce R

Úvod Datové struktury Vektory Datové tabulky Začínáme Datové typy Operace Matice Seznamy 0000000 0000

Literatura

- Karel Zvára. Základy statistiky v prostředí R. Praha, Česká republika: Karolinum, 2013. ISBN: 978-80-246-2245-3.
- Hadley Wickham. Advanced R. Boca Raton, FL: CRC Press, 2015. ISBN: 978-1466586963.

Datové struktury Vektory Datové tabulky Úvod Operace Seznamy

Proč bych se právě já měl učit s R

- s vědou (nejen) v biomedicíně to myslím vážně
- chtěl bych se věnovat postgraduálnímu doktorskému studiu, kde jistojistě budu potřebovat statistiku
- komerční statistické programy pro mě nejsou dostupné, nebo nejsou dobře použitelné
- sbírám opakovaně data stejného charakteru a rád bych si jejich (před)zpracování automatizoval
- publikuji v odborných časopisech a rád bych do statě článku s Methodology and Statistical Analysis pravdivě psal, že all statistical analyses were performed using R language for statistical computing and graphics...", protože existují důkazy, že citování R či jiných volných statistických nástrojů mnohdy zvyšuje pravděpodobnost citování takového článku





 Úvod
 Začínáme
 Datové typy
 Datové struktury
 Vektory
 Operace
 Matice
 Datové tabulky
 Seznamy

 00000 0
 000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000
 0000000

Proč bych se právě já měl učit s R

- tuším, že věda 2.0 v biomedicíně se bude provozovat nejen formou experimentů na živém (in vivo) či v laboratořích (in vitro), ale budou ji tvořit ze značné části počítačové modely a simulace (in silico)
- uvědomuji si, že MS Excel v základním rozhraní neumí doteď vykreslit krabicový diagram
- zpracování dat v tabulkových procesorech a spoléhání se jen na ně je spjato s různými problémy, chybné výstupy z tabulkových procesorů dokonce vyvolaly některé vědecké skandály
- data již nějakou dobu (sám) analyzuji a přemýšlím, který nástroj pro analýzu (s kvalitní dokumentací a živou podporou a komunitou) se začít učit



Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy 0000000

Co je R

Úvod



- R je interpretovaný programovací jazyk
- kombinuje několik paradigmat
 - imperativní
 - funkcionální
 - objektové
- R je domain specific language je určen pro statistickou analýzu dat a jejich grafické zobrazení
- R je open-source, konkrétně free-as-in-beer a free-as-in-speech

Lubomír Štěpánek

Stažení a instalace jádra R

na stránkách R-projectu

https://www.r-project.org/

postupně download R, vyberme českou doménu a stáhněme desktopově

poté instalujme dle instrukcí do předvolené složky



(CVUT

Stažení a instalace RStudia

- RStudio je jedním z grafických IDE (<u>Integrated Development Environment</u>) jazyka R
- na stránkách RStudia

https://www.rstudio.com/

- postupně Products > RStudio > Desktop > Open Source Edition > Free > Download, stáhněme desktopově
- poté instalujme dle instrukcí do předvolené složky



Ahoj světe!

Úvod

do skriptu či konzole napišme

```
print("hello world")
```

dostaneme

```
[1]
    "hello world"
```

Datové struktury Úvod Začínáme Datové typy Vektory Operace Matice Datové tabulky Seznamy

Práce s nápovědou

 nápovědu pro funkci či objekt získáme pomocí příkazu help(), kde argumentem je název funkce či objektu

- help(print)
 - nebo předsazením symbolu ? před název funkce či objektu
- ?print
 - předsazením symbolů ?? před název funkce či objektu prohledáme veškeré dokumenty nápovědy
- ??print
 - vždy je zavolán HTML soubor s volnotextovou nápovědou

14/56

Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy

Datové typy

Úvod

- numerická hodnota (numeric)
- celé číslo (integer)
- komplexní číslo (complex)
- logická hodnota (logical)
- textový řetězec (character)
- NA, NULL, NaN



Datové struktury Vektory Datové tabulky Úvod Datové typy Operace Matice Seznamy 0000000

Numerická hodnota

- v R jako numeric
- libovolné $x \in \mathbb{R}$ uložené s danou přesností
- odpovídá datovému typu double s 64 bitovou přesností, který je běžný v jiných jazycích
- např.

```
5; -13.8, 4.5578e15
```

zda je hodnota typu numeric, zjistíme pomocí

```
is.numeric(-13.8)
                         TRUE
class(-13.8)
                         "numeric"
class(Inf)
                         "numeric"
```

vhodná pro různorodé operace (viz dále)



Úvod Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy 0000000

Celé číslo

- v R jako integer
- libovolné $z \in \mathbb{Z}$ uložené s danou přesností
- např.

```
5L; 13L, -5L
```

zda je hodnota typu integer, zjistíme pomocí

```
is.integer(-13L)
                        TRIJF
class(-13L)
                      # "integer"
is.integer(-13)
                      # FALSE
class(-13)
                      # "numeric"
```

přetypování celého čísla na reálné (numeric) pomocí

```
as.numeric(5L)
```

- pozor! v R mají celá čísla pouze 16 bitovou přesnost
- pro práci s velkými celými čísly nutné balíčky gmp či int64 (zvýší bitovou přesnost uložených celých čísel)



Lubomír Štěpánek



Logická hodnota

- v R jako logical
- libovolné booleovské $x \in \{TRUE, FALSE\}$
- např.

```
TRUE; FALSE; T; F
```

zda je hodnota typu logical, zjistíme pomocí

```
is.logical(TRUE)
                                      TRUE
          class(FALSE)
                                      "logical"
3
          class("TRUE")
                                    # "character"
4
          class(T)
                                     "logical"
          class(F)
                                      "logical"
```

Úvod Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy 0000000

Textový řetězec

- v R jako character
- libovolná sekvence znaků (extended ASCII) uzavřená mezi jednoduchými či dvojitými uvozovkami
- např.

```
"ahoj"; 'xweiwogw23425ng';
```

zda je hodnota typu character, zjistíme pomocí

```
is.character("ahoj")
                                     TRIJF
          class("bla bla")
                                   # "character"
          class("123")
                                   # "character"
          class (123)
                                   # "numeric"
          is.numeric(Inf)
                                   # TRUE
6
          is.numeric("Inf")
                                   # FALSE
```

na textový řetězec lze převést libovolnou jinou hodnotu pomocí

```
as.character(123)
```



19/56

Operace Začínáme Datové typy Datové struktury Vektory Matice Datové tabulky Seznamy 0000000

NA. NULL. NaN

Úvod

- NA je hodnota typu Not Available, obvykle chybějící hodnota
- NULL je null object, používá se pro bezhodnotovou inicializaci objektu (uvidíme později)
- NaN je hodnota typu Not a Number, obvykle nevyjádřitelný výsledek matematické operace
- množinově platí {NaN} ⊂ {NA}
- např.

```
log(-1)
                                NaN
          is.na(NaN)
                                TRUE
          is.nan(NA)
                                FALSE
4
          is.nan(1 / 0)
                              # FALSE
          1 / 0
                              # Inf
```



Přiřazení hodnoty k proměnné

přiřadit hodnotu nějaké proměnné lze pomocí jednoduchého rovnítka

nebo pomocí orientované šipky

```
# totéž
```

• anebo pomocí funkce assign(), kde prvním argumentem je název proměnné (tedy textový řetězec) a druhým hodnota

```
assign("x", 5) # analogické k x \leftarrow 5 či x = 5
```

to se hodí zejména u dynamického iterování (viz později)



Úvod Začínáme Datové typy Datové struktury Operace Matice Datové tabulky Seznamy

Datové struktury

- vektor (vector)
- faktor (factor)
- matice (matrix)
- tabulka dat (data.frame)
- seznam (list)

(CVUT

22/56

Datové tabulky Úvod Datové typy Datové struktury Vektory Operace Matice Seznamy

Tvorba vektorů a základní příkazy

- vektor je jednorozměrný výčet prvků stejného datového typu, nemá orientaci ve smyslu řádek či sloupec
- vektor je objekt typu tuple, tedy zachovává pořadí svých prvků (na rozdíl od objektů typu set)
- lze vytvořit pomocí generické funkce c(), neboli concatenate
- např.

```
c()
               # prázdný vektor
length(c())
c(3, 1, 2)
               # vektor o délce 3 a prvcích 3, 1, 2
c("a", "d")
               # vektor o dél. 2 a prvcích "a", "d"
```

pomocí funkce c() lze vektory i prodlužovat

```
c(c(3, 1, 2), 4) # vektor o prvcich 3, 1, 2, 4
c(3, 1, 2, 4)
                   # zkráceně totéž
```



23/56

Tvorba vektorů a základní příkazy

vektor tedy lze prodloužit libovolně o jednu či více hodnot

```
x < -c(3, 1, 2)
           length(x)
           v <- 1
 4
           z < -c(2)
 5
           w < -c(5.7)
 6
           x < -c(x, y)
                               # prodloužení vektoru x
                               # o hodnotu y
 8
           W < - C(W, Z)
                               # prodloužení vektoru w
 9
                               # o vektor z
10
                               # jednoprvkový vektor je
11
                               # skalárem, jednou hodnotou
           c < -c(1, 2, 3)
13
                               # vektor o prvcích 1, 2, 3
14
                               # byť je c referovaný termín,
15
                               # funkce c je zachována
16
                                 a vznikl vektor c
```

Lubomír Štěpánek



Vektory textových řetězců

 vektory obsahující textové hodnoty, lze je použít např. jako názvy prvků jiného vektoru

```
x < -c(3, 1, 2)
          y <- c("a", "b", "c")
          names(x) <- y # pojmenuje prvky
                              # vektoru x
5
          X
6
          unname (x)
                              # zbaví prvky vektoru
                              # x jeho jejich jmen
8
          setNames(x, y)
                              # opět pojmenuje
                              # prvky vektoru x
```

21. září 2020

Subvektory, indexování, adresace

- R indexuje vektory od 1, nikoliv od 0 (první prvek má index 1, druhý index 2, apod.)
- adresujeme pomocí hranatých závorek []

```
x < -c(4, 2, 6,
         x[1]
                           \# c(4, 2)
         x[1:2]
4
         x [5]
5
         x[length(x)] # -3
6
         x[c(1, 3, 4)] # c(4, 6, -3)
         x[length(x):1] # c(-3, 6, 2, 4)
                           # totéž. c(-3, 6, 2, 4)
         rev(x)
```

Úvod Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy 000000 00000000 0000000

Logické vektory

používají se (nejen) k adresování vhodných prvků

```
y <- c(TRUE, TRUE, FALSE, TRUE) # loqický
                                             # vektor
3
         x < -c(3, 1, 2, 5)
                                # (sub)vektor c(3, 1)
         x [y]
         x[c(F, T, F, T)] # subvektor c(1, 5)
```

výhodný je někdy tzv. recycling

```
z <- c("R", "G", "E", "F", "I")
2
         z[c(T, F)] # vybere pouze hodnoty
                          # na lichých pozicích,
                          # tedy "R", "E", "I"
5
                          # neboli vektor
                          \# c("R", "E", "I")
```



Datové typy Datové struktury Vektory Operace Datové tabulky Úvod Začínáme Matice Seznamy 000000 00000000 00000000 000000

Faktory

vektory textových hodnot, kde každá hodnota patří do své kategorie

```
x <- factor(
              c("muž", "žena", "muž", "muž")
                    # pořadí kategorií je defaultně
                    # abecední
         x <- factor(
6
              c("muž", "žena", "muž", "muž"),
              levels = c("žena", "muž")
8
                    # zde si pořadí kategorií
9
                    # určíme sami
```

nad faktory snadno vytvoříme kontingenční tabulku

```
table(x)
              # žena muž
              # 1 3
```



Úvod Datové typy Datové struktury Operace Matice Datové tabulky Seznamy Začínáme •0000000 00000000 000000

Aritmetické operace

operace	operátor	příklad
sčítání	+	2 + 3
odčítání	-	2 - 3
násobení	*	2 * 3
dělení	/	2 / 3
mocnění	^ či **	2 ^ 3 či 2 ** 3
$modulo^1$	%%	7 %% 3
celočíselné dělení	%/%	7 %/% 3



¹zbytek po celočíselném dělení

Datové struktury Vektory Datové tabulky Úvod Začínáme Datové typy Operace Matice Seznamy 0000000 00000000 000000

Logické operace

- logické operace lze užít obecně nad výroky, tj. nad objekty s datovým typem logical
- operace short AND (operator &)
 - použitelná pro vektory
 - vyhodnocuje všechny výroky vektoru a vrací jejich hodnoty

```
c(FALSE, FALSE, TRUE, TRUE) &
c(FALSE, TRUE, FALSE, TRUE)
               # c(FALSE, FALSE, FALSE, TRUE)
```

- operace short OR (operator |)
 - použitelná pro vektory, vyhodnocuje všechny výroky vektoru a vrací jejich hodnoty

```
c(FALSE, FALSE, TRUE, TRUE) |
c(FALSE, TRUE, FALSE, TRUE)
      # c(FALSE, TRUE, TRUE, TRUE)
```



Logické operace

Úvod

- operace NOT (operator !)
 - vrací výroku opačnou logickou hodnotu, než které výrok nabývá

```
# FALSE
1 2 > 3
                         # TRUE
```

- funkce all()
 - vrací pro vektor výroků TRUE právě tehdy, jsou-li všechny výroky rovné TRUF

```
all(c(3 > 2, 7 \% 3 == 1, 1 == 0)) # FALSE
all(c(3 > 2, 7 \% 3 == 1, 1 >= 0))
                                    # TRUE
```

- funkce any()
 - vrací pro vektor výroků TRUE právě tehdy, je-li alespoň jeden z výroků roven TRUE

```
any(c(3 < 2, 7 \% 3 <= 0, FALSE))
                                      # FALSE
any(c(3 < 2, 7 \% 3 >= 1, FALSE))
                                      # TRUE
```

Lubomír Štěpánek

Operace porovnávání (komparace)

- pomocí operací porovnávání lze srovnat velikost či pořadí dvou objektů stejného datového typu; datový typ může přitom být v podstatě libovolný
- výsledkem operace porovnání je výrok, tedy hodnota datového typu logical
- porovnání typu je rovno (==, all.equal(), identical())

```
2 == 3
                                # FALSE
          all.equal(c(1, 2), c(1, 2 + 1e-13),
                     tolerance = 1e-12)
4
                                # TRUE; porovnává vektory
5
                                # volitelnou danou toleranci
6
          identical(c(1, 2), c(1, 2 + 1e-13))
                                # FALSE, porovnává objekty
8
                                # a vrací TRUE jen při úplné
9
                                # shodě
```



Lubomír Štěpánek

Operace porovnávání (komparace)

• porovnání typu je menší, je menší rovno, je větší, je větší rovno (<, <=, >, >=)

```
2 < 3
                                   TRUE
          "b" <= "a"
                                  # FALSE; porovnává pořadí
                                   v abecedě
          FALSE >= TRUE
                                  # FALSE; porovnává hodnotu
5
                                  # v booelovské aritmetice
6
                                  \# (TRUE := 1, FALSE := 0)
```

porovnání typu není rovno, je různé od (!=)

```
TRUF
TRUE != FALSE
                      # TRUE
```



Operace porovnávání (komparace)

porovnání typu je obsaženo ve (%in%)

```
c(2, 6) \%in\% c(1:5)
                                      # c(TRUE, FALSE)
         "k" %in% LETTERS
                                      # FALSE
         "J" %in% letters
                                      # FALSE
4
         "May" %in% month.name
                                      # TRUE
5
         '%in%'("Jan", month.abb)
                                      # TRUE; prefix notace
         "a" %in% "abeceda"
                                      # FALSE
```

ekvivalentem (wrapperem) operace %in% je funkce is.element()

```
is.element(c(2, 6), c(1:5))
                                      # c(TRUE, FALSE)
          is.element(c(1:5), c(2, 6))
4
                                      # c(FALSE, TRUE,
                                      # FALSE, FALSE, FALSE)
```

funkce typu je pravdou (isTRUE())

 $isTRUE(3^2 > 2^3)$ # TRUE



Vestavěné matematické funkce

- jde o funkce balíčků base, stats a dalších, je jich obrovské množství
- např.

```
abs(), sign()
          acos(), asin(), atan()
          sin(), cos(), tan()
4
          ceiling(), floor(), trunc()
5
          exp(), log(), log10(), log2(), sqrt()
6
          max(), min(), prod(), sum()
          cummax(), cummin(), cumprod(), cumsum(),
             diff()
          pmax(), pmin()
          range()
10
          mean(), median(), cor(), sd(), var()
          rle()
```



Zaokrouhlování, formátování čísel

 zaokrouhlení čísla x pomocí round(x, digits) na digits desetinných míst

```
1 | round(1.4, digits = 0) # 1
2 | round(-146.655, 2) # -146.66
```

 zaokrouhlení čísla x pomocí signif(x, digits) na digits platných cifer

```
1 signif(1.458, digits = 1) # 1
2 signif(1.458, digits = 2) # 1.5
3 signif(1.458, digits = 3) # 1.46
4 signif(1.458, digits = 4) # 1.458
```

 formátování čísla x pomocí format(x, nsmall) na nsmall fixních desetinných cifer

```
1 | format(1.45, nsmall = 1) # "1.45"
2 | format(1.45, nsmall = 2) # "1.45"
3 | format(1.45, nsmall = 3) # "1.450"
```

Tvorba matic a základní příkazy

- matice (matrix) je dvojrozměrným polem, které obsahuje prvky stejného datového typu
- všechny sloupce matice mají shodnou délku, podobně všechny řádky matice mají shodnou délku
- ať je

$$\mathbf{A} = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix} \qquad \mathbf{B} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

v R matici A a B získáme příkazy

```
A <- matrix(c(1, 2, 3, 4), nrow = 2,

ncol = 2)

B <- matrix(c(1, 3, 2, 4), nrow = 2,

ncol = 2)

B <- matrix(c(1, 2, 3, 4), nrow = 2,

ncol = 2, byrow = TRUE)

# vždy jeden z argumentů "nrow" či "ncol" je zbytný
```



Manipulace s maticemi

ať je

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

v R pak pomocí

```
<- matrix(letters[1:12], nrow =</pre>
            byrow = T)
```

některé užitečné příkazy

```
is.matrix(C)
                 # TRUE
class(C)
                 # "matrix"
mode(C)
                 # "character"; datový typ prvků
                 # chr [1:3, 1:4] "a" "e" "i" ...
str(C)
dim(C)
                 # c(3, 4); rozměry matice C
```



Manipulace s maticemi

ať je

Úvod

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

další užitečné příkazy

```
colnames(C) <- c("c1", "c2", "c3", "c4")
          rownames(C) <- c("r1", "r2", "r3")
                      # přidá jmenovky sloupcům i řádkům
          C \le unname(C)
5
                      # zbaví sloupce i řádky jmenovek
6
7
8
          dimnames(C) <- list(
                               c("r1", "r2", "r3"),
                               c("c1", "c2", "c3", "c4")
10
                      # opět přidá jmenovky sloupcům i řádkům
```



Manipulace s maticemi

stále mějme

Úvod

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

další užitečné příkazy

```
rbind(C, c("x", "x", "x", "x"))
1
2
3
4
5
                      # přidání řádku c("x", "x", "x". "x")
                      # k matici C
          cbind(C, c("x", "x", "x"))
                      # přidání sloupce c("x", "x", "x")
                      # k matici C
          C[-1,] # odebrání 1. řádku matici C
          C[, -2] # odebrání 2. sloupce matici C
```



Submatice, indexování, adresace

ať je

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

v R pomocí

```
C <- matrix(letters[1:12], nrow = 3,</pre>
             byrow = T, dimnames = list(
             c("r1", "r2", "r3"),
             c("c1", "c2", "c3", "c4")))
```

adresace

```
C[2, 3]
              # "q"; prvek 2. řádku, 3. sloupce
C["r2", "c3"] # "g"; prvek 2. řádku, 3. sloupce
C[1, ]
            # c("a", "b", "c", "d");
                # tedy vektor 1. řádku matice C
                # s popisky
```





Submatice, indexování, adresace

stále mějme

Úvod

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

adresace

```
C[, 3]
                            # c("c", "q", "k");
1
2
3
                             # tedy vektor 3. sloupce matice C
                             # s popisky
           C[c(1, 3), c(2, 4)]
                             # matrix(c("b", "j", "d", "l"), 2)
6
7
8
                             # submatice 1. a 3. řádku.
                             # 2. a 4. sloupce matice C
                             # s popisky
           C["r2", ]
                             # c("e", "f", "q", "h");
10
                             # tedy vektor 2. řádku matice C
                             # s popisky
```

Submatice, indexování, adresace

stále mějme

$$C = \begin{pmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \end{pmatrix}$$

adresace

```
C[dim(C)[1], dim(C)[2]]
                       # "l"; obecná adresace prvku
                       # vpravo dole (např. neznáme-li
                       # číselné rozměry matice)
          C[5]
                      # "f"; major-column ordering
6
7
8
          C[c(8, 9)] # c("q", "k")
          C[13] # NA
          diag(C) # c("a", "f", "k"); hlavní diagonála
          diag(C[, dim(C)[2]:1])
10
                       # c("d", "q", "j"); vedlejší diagonála
```



Maticová algebra

buďte

Úvod

$$\mathbf{A} = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix} \qquad \mathbf{B} = \begin{pmatrix} 5 & 7 \\ 6 & 8 \end{pmatrix}$$

v R

- Hadamardův součin (*element-wise*, *pairwise*) $m{A} \circ m{B} = \begin{pmatrix} 5 & 21 \\ 12 & 32 \end{pmatrix}$
- # matrix(c(5, 12, 21, 32), 2)
- maticový součin $A \cdot B = \begin{pmatrix} 23 & 31 \\ 34 & 46 \end{pmatrix}$
- A %*% B # matrix(c(23, 34, 31, 46), 2)
 - transpozice $A^T = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$



Datové typy Datové struktury Vektory Operace Datové tabulky Úvod Seznamy

Tvorba datových tabulek a základní příkazy

- datová tabulka (data.frame) je dvojrozměrným polem, které obsahuje v každém sloupci prvky stejného datového typu, ale jednotlivé sloupce se mohou datovým typem lišit
- všechny sloupce datové tabulky mají shodnou délku, podobně všechny řádky datové tabulky mají shodnou délku
- v R je řada vestavěných datových tabulek

```
mtcars
          str(mtcars)
          class(mtcars)
                                      # "data.frame"
                                      # "list"
          mode (mtcars)
5
          is.data.frame(mtcars) # TRUE
6
          str(iris)
               # 'data.frame': 150 obs. of 5 variables
8
               # . . .
9
          dim(iris)
                                      \# c(150, 5)
```









Manipulace s datovými tabulkami

užitečné příkazy

Úvod

```
data <- mtcars
           colnames (data)
           colnames(data) <- paste("c",</pre>
                                        1: dim(data)[2],
 5
                                        sep = "_")
 6
           rownames(data) <- paste("r",
                                        1: dim(data)[1],
 8
                                        sep = "_")
 9
                            # změní jmenovky sloupcům i řádkům
10
           head (data)
                            # náhled na prvních 6 řádků
11
           head (data,
                       10)
12
                            # náhled na prvních 10 řádků
13
           tail(data)
                              náhled na posledních 6 řádků
14
           tail(data, 10)
15
                            # náhled na posledních 10 řádků
```

Manipulace s datovými tabulkami

další užitečné příkazy

```
rbind(data, rep(0, dim(data)[2]))
                          # přidání řádku c(0, 0, ..., 0)
                          # k data.frameu "data"
           cbind(data, rep(0, dim(data)[1]))
 5
                          # přidání sloupce c(0, 0, \ldots, 0)
 6
                          # k data.frameu "data"
           data.frame(data,
 8
                         "ahoj" = rep(0, dim(data)[1]))
 9
                          # přidání sloupce c(0, 0, ..., 0)
10
                          # se jménem "ahoj" k data.frameu
11
                          # "data"
12
           data[-1,] # odebrání 1. řádku data.frameu
13
                          # "d.a.t.a."
14
           data[, -1] # odebrání 1. sloupce data.frameu
15
                          # "d.a.t.a."
```



Indexování, adresace

adresace

```
data[2, 3]
                             # 160; prvek 2. řádku, 3. sloupce
            data["r_2",
                          "c_3"]
                             # 160; prvek pod danými popisky
 4
                             # c(21, 6, 160, 110, ...);
           data[1, ]
 5
                             # tedy vektor 1. řádku data.frameu
 6
                             # "data" s popisky
                             \# c(6, 6, 4, 6, \ldots);
            data[, 2]
 8
                             # tedy vektor 2. sloupce
 9
                             # data.frameu "data" s popisky
10
           data$c_5
                             \# c(3.90, 3.90, 3.85, 3.08, ...);
11
                             # tedy vektor 2. sloupce
12
                               data.frameu "data" s popisky
13
            data$c_5[1]
                             # 3.9:
14
                             # tedy první prvek 2. sloupce
15
                             # data.frameu "data"
```

Lubomír Štěpánek



Indexování, adresace

adresace

```
data[dim(data)[1], dim(data)[2]]
2
                        # 2; obecná adresace prvku
                        # vpravo dole (např. neznáme-li
                        # číselné rozměry tabulky)
5
          data[5]
                         5. sloupec, nikoliv major-column
6
                        # ordering
```

Sloupcové přehledy

• může mít smysl znát agregovaný ukazatel nad všemi sloupci

```
colSums (data)
                        # součty všech sloupců
           apply(data, 2, sum)
 4
                        # totéž
 5
           colMeans (data)
6
                        # průměry všech sloupců
           apply(data, 2, mean)
8
                        # totéž
9
           data <- rbind(data, rep(NA, dim(data)[2]))
10
                        # přidán řádek c(NA, NA, ...)
11
           colMeans (data)
12
                        # c(NA, NA, ...); pro získání průměrů
13
                        # nutné přidat arqument na.rm = TRUE
14
           colMeans(data, na.rm = TRUE)
15
           apply(data, 2, mean, na.rm = TRUE)
16
                        # už funguje
```

Lubomír Štěpánek

Tvorba seznamů a základní příkazy

- seznam (list) je výčtem prvků, které mohou být různorodého datového typu, včetně listu
- délky jednotlivých prvků seznamu se mohou lišit

```
mv_list <- list("a" = c(1:10),
                           "b" = mtcars,
3
                           "c" = matrix(1:8, 2),
4
                           z'' = ahoj''
5
         str(my_list)
6
         class(my_list)
                                   # "list"
         mode(my_list)
                                   # "list"
8
         is.list(my_list)
                                   # TRUE
```

Úvod Začínáme Datové typy Datové struktury Vektory Operace Matice Datové tabulky Seznamy

Manipulace se seznamy

užitečné příkazy

```
names(my_list)
           names(my_list) <- LETTERS[</pre>
3
                1:length(my_list)
                         # přejmenovávám prvky listu
5
6
           my_list[[length(my_list) + 1]] <- c(T, F)
           names(length(my_list)) <- "XY"</pre>
8
                         # přidání vektoru c(T, F)
9
                         # k listu "my_list" pod jménem
10
                         # "XY"
```

Indexování, adresace

adresace

```
my_list[[2]] # 2. prvek listu
           my_list[["B"]]
                            # prvek listu pod jmenovkou
 4
                            # jde o původní datový typ
 5
                            # (data.frame)
6
           my_list["B"]
                            # prvek listu pod jmenovkou
                            # jde (vždy) o list
8
           my_list[c(2, 4)]
9
                            # 2. a 4. prvek listu
10
                            # prvek listu pod jmenovkou
           my_list$C
11
           my_list[[1]][2]
12
                            # 2; 2. prvek 1. prvku listu
13
           my_list[[2]][3, 5]
14
                            # 3.85; z 2. prvku listu vybírám
15
                            # prvek o souřadnicích (3, 5)
```

Indexování, adresace pomocí funkce lapply()

adresace

```
set.seed(1)
          my_long_list <- lapply(
               sample(c(80:120), 100, TRUE),
               function(x) sample(
5
                    c(50:150), x, replace = TRUE
6
               # list vektorů náhodné délky
8
               # generovaných z náhodných čísel
9
10
          lapply(my_long_list, "[[", 14)
11
               # z každého prvku listu (vektoru)
               # vybírám jen jeho 14. prvek
```

Prvkové přehledy

může mít smysl znát agregovaný ukazatel nad všemi prvky seznamu

```
lapply(my_long_list, mean)
2
               # pro každý prvek listu (vektor)
               # vracím jeho průměr
4
5
          lapply(my_long_list, length)
6
               # pro každý prvek listu (vektor)
               # vracím jeho délku
```

Děkuji za pozornost!

lubomir.stepanek@lf1.cuni.cz lubomir.stepanek@fbmi.cvut.cz



https://github.com/LStepanek/17VSADR Skriptovani a analyza dat v jazyce R

